Univerzitet u Sarajevu

Elektrotehnički fakultet

Seminarski rad

NEURONSKE MREŽE KAO GRAFOVI: STRUKTURA, DINAMIKA I OTPORNOST

Student: Rubina Rekić

Mentor: prof. dr. Razija Turčinhodžić Mulahasanović

Sarajevo, decembar 2025.

Sadržaj

1 Uvod **2**
1.1 Kontekst i motivacija . . . 2
1.2 Ciljevi rada . . . 2

2 Metodologija **3**
2.1 Modeliranje neuronske mreže . . . 3
2.2 Strukturalna analiza . . . 3
2.3 Simulacija dinamike signala . . . 3
2.4 Analiza otpornosti mreže . . . 3

3 Faza 1: Strukturalno modeliranje i analiza (Teorija grafova) **4**
3.1 Težinski usmjereni graf: modeliranje sinapsi . . . 4
3.2 Odabir topologije mreže . . . 5
3.2.1 Usmjeravanje Barabási–Albert modela i biološki kontekst . . . 6
3.3 Biološka validacija težina: Daleov zakon . . . 7
3.4 Metrike strukturalne analize i identifikacija ključnih čvorova . . . 7
3.5 Matrica susjedstva neuronske mreže . . . 8
3.6 Implementacija modela i numerički rezultati . . . 8
3.7 Vizualizacija i interpretacija rezultata . . . 9
3.8 Vizualizacija topološke strukture . . . 10

4 Faza 2: Dinamička simulacija propagacije signala **12**
4.1 Teorijski i biološki okvir dinamičke simulacije . . . 12
4.1.1 Sumacija i integracija signala (Prag θ) . . . 12
4.1.2 Refraktorni period i metabolički oporavak . . . 12
4.1.3 Disipacija i slabljenje signala . . . 13
4.1.4 Sinaptička plastičnost i Hebbovo učenje (Parametar η) . . . 13
4.2 Matematički model dinamike . . . 13
4.2.1 Stanje neurona . . . 13
4.2.2 Neto ulazni signal . . . 13
4.2.3 Pravilo aktivacije . . . 14
4.2.4 Dinamika metaboličke energije . . . 14
4.2.5 Specifičnost energetskog modela i cilj simulacije . . . 14
4.2.6 Hebbovo učenje . . . 14
4.2.7 Diskretna simulacija i inicijalna stimulacija . . . 14
4.2.8 Napomena o stabilnosti . . . 15
4.2.9 Asinhrona aktivacija . . . 15
4.2.10 Kriterij zaustavljanja simulacije . . . 15
4.2.11 Parametrizacija modela . . . 15
4.3 Implementacija dinamike . . . 15
4.4 Scenariji simulacije i biološka interpretacija . . . 16
4.4.1 Scenarij 1: Aktivacija hub-neurona . . . 16
4.4.2 Scenarij 2: Aktivacija perifernog neurona . . . 18
4.5 Video simulacija i interaktivni prikaz . . . 20

5 Faza 3: Analiza Otpornosti **21**
5.0.1 Matematički model . . . 21
5.0.2 Implementacija i algoritamski pristup . . . 22
5.0.3 Analiza efikasnosti komunikacije (Average Shortest Path Length) . . . 24

6 Poveznica s vještačkim neuronskim mrežama **26**
6.1 Strukturalna veza između grafovskog modela i vještačkih neuronskih mreža . . . 26
6.2 Dinamička veza: propagacija signala u vještačkim neuronskim mrežama . . . 26
6.3 Otpornost i robusnost neuronskih arhitektura . . . 27

7 Zaključak **28**

8 Reference **29**

A Programski kod **30**

1 Uvod

1.1 Kontekst i motivacija

Razumijevanje bioloških neuronskih mreža predstavlja jedan od glavnih izazova savremene nauke. Neuroni u ovim mrežama međusobno su povezani velikim brojem veza, a njihovu aktivnost karakterišu nelinearne interakcije i višeslojna zavisnost. Ključno pitanje koje se ovdje postavlja je kako topološka struktura mreže utiče na njenu funkcionalnu dinamiku, tj. način na koji se signali šire kroz mrežu, te na njenu otpornost na oštećenja ili gubitak pojedinih neurona.
Tradicionalne metode analize neuronskih mreža, kao što su statistički pregledi aktivnosti pojedinih neurona ili jednostavne matrice povezanosti, često nisu dovoljne za kvantifikaciju složene arhitekture sistema. One mogu opisati osnovne odnose između nekoliko neurona, ali ne mogu uhvatiti globalne karakteristike mreže, kao što su centralni čvorovi, grupisanje neurona u funkcionalne module ili otpornost mreže na oštećenja. S obzirom na masivnu povezanost i nelinearne interakcije u mreži, potrebni su alati koji omogućavaju analizu i vizualizaciju cijele strukture na višem nivou.

U tom kontekstu, teorija grafova se pojavljuje kao moćan matematički okvir koji omogućava modeliranje neuronske mreže kroz čvorove (neurone) i veze (sinapse), te primjenu različitih algoritama za analizu strukture i funkcionalne dinamike.[1]
Pored statičke analize topologije, grafovski modeli omogućavaju i simulaciju dinamike širenja signala kroz mrežu, čime se može proučavati uticaj strukture na vremensku evoluciju neuronske aktivnosti.
Ključne grafovske metode koje se koriste u ovom kontekstu uključuju:

- **Centralnost čvorova** (degree, betweenness) – za identifikaciju neurona koji imaju najveći utjecaj na prenos informacija u mreži;
- **Klaster koeficijent i modularnost** – za otkrivanje lokalnih grupa neurona i funkcionalnih modula unutar mreže;
- **Analiza najkraćih puteva i povezanosti** – za procjenu kako signali putuju kroz mrežu i koliko je mreža otporna na uklanjanje pojedinih čvorova;
- **Algoritmi za simulaciju propagacije signala** – za vizualizaciju dinamike aktivacije kroz mrežu i proučavanje efekta stimulacije ili inhibicije određenih čvorova.

Kombinacija ovih metoda omogućava dublje razumijevanje kako topološka struktura mreže utiče na njenu funkcionalnu dinamiku i otpornost, što je glavni cilj ovog rada.

Iako je fokus primarno na biološkim neuronskim mrežama, metode koje će biti opisane u radu mogle bi se primijeniti i na vještačke neuronske mreže, koje dijele slične principe organizacije i dinamike, čime se otvara mogućnost interdisciplinarne primjene.

1.2 Ciljevi rada

Ovaj rad ima za cilj uspostaviti i analizirati model neuronske mreže pomoću algoritama teorije grafova, kako bi se razumjele međusobne interakcije neurona i način na koji mreža reaguje na različite promjene ili oštećenja.
U svrhu ispunjavanja postavljenog cilja, rad je podjeljen u tri međusobno povezane faze:

- **Strukturalna analiza:** Neuronska mreža modelira se kao graf, gdje čvorovi predstavljaju neurone, a grane sinapse. U ovom dijelu, planirana je analiza ključnih strukturalnih metrika, uključujući centralnost čvorova, distribuciju stepena, klaster koeficijent i modularnost, kako bi se dobio dobar uvid u topološka svojstva mreže.
- **Dinamička simulacija:** U ovoj fazi simuliraće se širenje biološkog signala kroz mrežu, uključujući utjecaj aktivacije i inhibicije pojedinih čvorova. Vizualizacija toka signala omogućit će bolje razumijevanje dinamike neuronskog sistema i načina na koji struktura mreže utiče na protok informacija.
- **Eksperimentalno modeliranje otpornosti:** U ovoj fazi će se ispitivati sposobnost mreže da zadrži funkcionalnost nakon uklanjanja kritičnih čvorova. Ciljano uklanjanje vršiće se prema različitim metrikama centralnosti, a rezultati će se uporediti s efektom nasumičnog uklanjanja čvorova, čime će se demonstrirati otpornost mreže i značaj ključnih neurona.

Kombinacijom ovih faza, rad bi trebalo da omogući integrisani pristup: spaja teorijsku analizu strukture, simulaciju funkcionalne dinamike i ispitivanje otpornosti mreže.

2 Metodologija

Sve simulacije i analize implementirane su u programskom jeziku Python, koristeći specijalizovane biblioteke:

- **NetworkX** – manipulacija i analiza grafova;
- **networkx.algorithms.community** – detekcija zajednica i analiza modularnosti;
- **NumPy** – numerički proračuni i generisanje slučajnih podataka;
- **Matplotlib** – statička vizualizacija, uključujući **matplotlib.animation.FuncAnimation** za animacije toka signala;
- **copy** – omogućava kreiranje dubokih kopija mreže, što je ključno za analizu otpornosti pri uklanjanju čvorova.

2.1 Modeliranje neuronske mreže

Neuronska mreža modelira se kao usmjereni graf sa čvorovima (neuroni) i granama (sinapse). Svaki neuron ima tip ekscitatorni (E) ili inhibitorni (I), dok se težine veza dodjeljuju nasumično ovisno o tipu izvornog neurona. Struktura mreže generiše se prema Barabási-Albert modelu (N=300, m=3), čime se osigurava prisustvo HUB čvorova i distribucija stepena slična biološkim mrežama.

2.2 Strukturalna analiza

Analiza mreže uključuje:

- distribuciju stepena čvorova i identifikaciju HUB, srednjih i perifernih neurona;
- centralnost čvorova (betweenness) za identifikaciju ključnih čvorova;
- klaster koeficijent za procjenu lokalnog grupisanja neurona;
- modularnost i detekciju zajednica putem networkx.algorithms.community.

Rezultati vizualizuju se histogramima i grafovima mreže sa bojama koje označavaju kategorije čvorova.

2.3 Simulacija dinamike signala

Širenje signala simulira se diskretnim vremenskim koracima:

- svaka aktivacija neurona zavisi od ulaznih signala, praga (theta) i energijskog stanja neurona;
- težine sinapsi se adaptiraju tokom simulacije;
- tok signala vizualizuje se kroz animacije i snimke ključnih koraka, koristeći **FuncAnimation**, uz označavanje HUB, srednjih i perifernih čvorova.

2.4 Analiza otpornosti mreže

Otpornost se procjenjuje uklanjanjem čvorova po dvije strategije:

- nasumično uklanjanje (simulacija slučajne smrti neurona);
- ciljani napad (uklanjanje HUB čvorova po betweenness centralnosti).

Efekti uklanjanja mjere se veličinom najveće snažno povezane komponente (LSCC) i prosječnom dužinom najkraćih puteva između preostalih čvorova. Biblioteka **copy** omogućava kreiranje dubokih kopija mreže kako bi originalna mreža ostala netaknuta za ponovnu upotrebu u različitim scenarijima.

3 Faza 1: Strukturalno modeliranje i analiza (Teorija grafova)

Modeliranje neuronske mreže započinje njenim pretvaranjem u matematički objekat – graf. Sam pojam grafa je intuitivno vrlo lako shvatiti, ali ga je formalno nešto teže definisati. Obzirom da se u literaturi nalazi više različitih definicija, koje se međusobno razlikuju, kako po složenosti, tako i po općenitosti, potrebno je na ovom mjestu dati definiciju grafa koja će biti korištena dalje u radu.

U daljem razmatranju, smatraćemo da je graf definisan kao uređeni par (X, R) gdje:

- X predstavlja skup **čvorova grafa** (čvorovi su u našem slučaju neuroni),
- R predstavlja **grane grafa**; formalno to je neka binarna relacija u skupu X, $\mathcal{R} \subseteq X \times X$, pri čemu vrijedi $(x_i, x_j) \in \mathcal{R}$ ako i samo ako su, intuitivno posmatrano, elementi x_i i x_j povezani granom (grane u našem slučaju modeliraju sinaptičke veze između neurona).[2]

3.1 Težinski usmjereni graf: modeliranje sinapsi

Iako se u teoriji grafova, zavisno od toga da li je relacija **R** simetrična ili asimetrična, grafovi dijele na neusmjerene i usmjerene respektivno, u ovom radu ćemo se isključivo fokusirati na **usmjerene grafove**.
Razlog za ovakav pristup leži u samoj prirodi bioloških neuronskih mreža – prenos nervnog impulsa je striktno usmjeren proces. Ovaj proces, ako i argumenti za odabir usmjerenog grafa pri modeliranju bit će detaljnije objašnjeni u nekoj od narednih sekcija. Ovdje je jedino bitno spomenuti da modeliranje mreže kao usmjerenog grafa omogućava da razlikujemo ulazne i izlazne veze svakog čvora, što je ključno za razumijevanje hijerarhije i protoka informacija u sistemu.

U mnogim primjenama teorije grafova, od ključne je važnosti granama pridružiti numeričke vrijednosti koje opisuju intenzitet veze. Dok u transportnim mrežama te vrijednosti predstavljaju dužinu puta ili troškove, u neuronskim mrežama svakoj grani potrebno je pridružiti realan broj koji direktno kvantifikuje sinaptičku snagu (intenzitet) veze između dva neurona. Bez ovog parametra bilo bi nemoguće modelirati osnovne biološke procese: mjeru u kojoj jedan neuron stimuliše (ekscitacija) ili suzbija (inhibicija) aktivnost drugog neurona.
Stoga, modeliranje neuronske mreže nužno zahtijeva prelazak sa običnih na težinske grafove.

Prema prethodno uvedenoj formalizaciji, prema kojoj se grafovi posmatraju kao uređeni parovi oblika $(X, \mathcal{R})$, težinski grafovi se obično definiraju kao uređene trojke oblika

$$(X, \mathcal{R}, f)$$

gdje su X i $\mathcal{R}$ definirani kao u slučaju običnih grafova, dok je $f : \mathcal{R} \to \mathbb{R}$ funkcija koja svakoj grani iz $\mathcal{R}$ pridružuje neki realni broj, odnosno njenu težinu.[2]
Tu težinu ćemo u daljim razmatranjima označavati sa w_{ij}
U našem modelu, težina grana nosi specifičnu biološku interpretaciju:

- $w_{ij} > 0$: Ekscitatorna veza koja povećava vjerovatnoću aktivacije ciljnog neurona.
- $w_{ij} < 0$: Inhibitorna veza koja smanjuje vjerovatnoću aktivacije.
- $|w_{ij}|$: Magnituda težine predstavlja efikasnost sinapse u prenosu signala.

Intuitivno, težinu w_{ij} možemo posmatrati kao 'filter' ili 'pojačalo' signala koji putuje kroz mrežu. U biološkom smislu, jedan neuron može slati identičan impuls svim svojim susjedima, ali upravo težine sinapsi određuju koliki će dio tog impulsa zapravo 'osjetiti' ciljni neuroni. Ako je $|w_{ij}|$ blizu nuli, veza je funkcionalno zanemariva, čak i ako se radi o fizički postojećem spoju. S druge strane, visoka apsolutna vrijednost težine ukazuje na dominantnu sinapsu koja ima moć da sama pokrene ili spriječi aktivaciju susjednog neurona. Na nivou cijele mreže, ove težine kreiraju **hijerarhiju važnosti**: one usmjeravaju tok informacija, favorizujući određene puteve prenosa signala dok druge potiskuju. Upravo ta varijabilnost težina omogućava neuronskoj mreži da 'uči' i prilagođava svoju dinamiku, pretvarajući statičnu strukturu grafa u živ, funkcionalan sistem.
Ono što je jako bitno spomenuti u kontekstu modeliranja jeste da u realnim biološkim sistemima ove težine nisu raspoređene simetrično. Kako bi se postigao visok stepen biološke vjerodostojnosti, u ovom radu se primjenjuje **Daleov zakon**, koji definiše strogi balans između ekscitatornih i inhibitornih neurona, što će biti detaljnije opisano u nastavku.

3.2 Odabir topologije mreže

Nakon formalnog definiranja neuronske mreže kao usmjerenog težinskog grafa, sljedeći ključni korak predstavlja odabir odgovarajuće topologije mreže, odnosno načina na koji su čvorovi međusobno povezani.
Topologija mreže ima presudan utjecaj na njena strukturalna i dinamička svojstva, te direktno određuje način širenja signala, otpornost na oštećenja i ulogu pojedinih čvorova unutar sistema.

U teoriji grafova i kompleksnih mreža razvijen je čitav niz modela mrežnih topologija. Najčešće korišteni modeli uključuju:

- **Nasumične mreže** (Erdős–Rényi model), gdje su veze između čvorova formirane slučajno;
- **Mreže malog svijeta** (Watts–Strogatz model), koje kombinuju visoku lokalnu povezanost s kratkim prosječnim putevima;
- **Skalno-invarijantne mreže** (Barabási–Albert model), koje karakteriše nehomogena raspodjela povezanosti i prisustvo visoko povezanih čvorova.

Prilikom odabira topologije mreže, autorica se pri svom pristupu oslonila na realnu biološku organizaciju neuronskih mreža.Naime, biološke neuronske mreže u pravilu ne posjeduju uniformnu ili nasumičnu strukturu. Eksperimentalna istraživanja pokazuju da mali broj neurona ima izuzetno veliki broj veza, dok većina neurona učestvuje u relativno malom broju sinaptičkih interakcija. Takva organizacija ukazuje na postojanje tzv. *hub* neurona, koji igraju dominantnu ulogu u prenosu i integraciji informacija. Ova osobina nije karakteristična za nasumične mreže, ali je prirodno prisutna u skalno-invarijantnim mrežama.

Iz tog razloga, u ovom radu je kao osnovni model topologije odabran **Barabási–Albert (BA) model**, koji generiše mreže sa skalno-invarijantnom strukturom. Intuitivno, ovaj model odražava princip po kojem novi neuroni, tokom razvoja ili učenja, imaju veću vjerovatnoću da se povežu s već postojećim, dobro povezanim neuronima. Drugim riječima, neuroni koji su već funkcionalno važni imaju tendenciju da postanu još važniji, čime se spontano formira hijerarhijska struktura mreže.[3]

Matematički, Barabási–Albert model zasniva se na dva osnovna mehanizma:

1. **Rast mreže**: mreža se gradi iterativno, dodavanjem novih čvorova tokom vremena;
2. **Preferencijalno povezivanje**: vjerovatnoća da se novi čvor poveže s postojećim čvorom proporcionalna je stepenu tog čvora.

U modelu koji razvijamo u okviru ovog rada, parametar m označavaće broj novih sinaptičkih veza koje svaki novi neuron uspostavlja pri ulasku u mrežu, čime se direktno kontroliše gustina veza (u našem slučaju $m = 3$).

Formalno, neka u trenutku t mreža sadrži $N(t)$ čvorova, a stepen čvora x_i označen sa k_i. Vjerovatnoća $P(x_i)$ da se novi čvor poveže sa čvorom x_i data je izrazom:

$$P(x_i) = \frac{k_i}{\sum_j k_j}.$$

Ovaj mehanizam dovodi do pojave stepenaste raspodjele koja slijedi zakon snage:

$$P(k) \sim k^{-\gamma},$$

gdje je eksponent γ tipično u intervalu $2 < \gamma < 3$. Takva raspodjela implicira da ne postoji karakterističan stepen mreže, već da se struktura mreže ponaša isto na različitim skalama, što je osnovna osobina skalno-invarijantnih mreža.[3, 4]

Primjena Barabási–Albert modela u kontekstu neuronskih mreža omogućava prirodno modeliranje heterogene strukture sistema, identifikaciju ključnih neurona putem mjera centralnosti, te realističnu analizu otpornosti mreže na gubitak čvorova. Upravo zbog ovih osobina, BA model predstavlja pogodan i biološki motivisan izbor za dalju strukturalnu i dinamičku analizu u ovom radu.

3.2.1 Usmjeravanje Barabási–Albert modela i biološki kontekst

Prethodno smo dali definiciju usmjerenog grafa, i objasnili da ćemo u kontekstu ovog rada raditi isključivo sa usmjerenim grafovima. U ovoj sekciji bit će objašnjena biološka potpora za takvu odluku, kao i način kako će modeliranje biti provdeno u praksi.
Standardni Barabási–Albert (BA) model je izvorno definisan kao neusmjeren graf, ali njegova direktna primjena u tom obliku nije u potpunosti prikladna za modeliranje bioloških neuronskih mreža. Razlog za to leži u činjenici da je sinaptički prenos signala u nervnom sistemu u svom osnovnom obliku jednosmjeren proces: nervni impuls se širi od presinaptičkog neurona, preko aksona, ka postsinaptičkom neuronu. Neusmjereni graf bi, stoga, implicitno sugerisao simetričan uticaj između neurona, što nije u skladu s neurobiološkom realnošću.

U ovom radu, neusmjerena topologija generisana Barabási–Albert modelom koristi se kao opis *strukturalne povezanosti* neuronske mreže, odnosno potencijalne anatomske bliskosti između neurona. Međutim, kako bi se omogućilo realističko modeliranje dinamike prenosa signala, svakoj vezi se naknadno pridružuje orijentacija, čime se dobija **usmjerena skalno-invarijantna mreža**. Ovaj postupak ne narušava osnovna statistička svojstva BA modela, poput stepenaste raspodjele koja slijedi zakon snage, ali omogućava jasnu distinkciju između ulaznih i izlaznih veza svakog čvora.

Uvođenje usmjerenosti ima ključnu ulogu u interpretaciji funkcionalnih uloga neurona unutar mreže. Neuroni sa visokim ulaznim stepenom (k_{in}) djeluju kao integracijski centri koji sabiraju informacije iz velikog broja izvora, dok neuroni sa visokim izlaznim stepenom (k_{out}) imaju dominantnu ulogu u distribuciji signala kroz mrežu. Ova razlika je od fundamentalnog značaja za analizu hijerarhije i protoka informacija, ali se ne može formalno uvesti u okviru neusmjerenog grafovskog modela.[1]

Dodatno, usmjerenost veza predstavlja neophodan uslov za očuvanje uzročnosti u dinamičkom modelu koji će biti razmatran u narednoj fazi rada. Signal generisan na neuronu u trenutku t može uticati samo na neuronsku aktivnost njegovih postsinaptičkih ciljeva u trenutku $t + 1$, osim u slučaju postojanja eksplicitnih povratnih veza. Time se izbjegavaju nerealistične simultane interakcije i implicitne povratne petlje koje bi se neminovno pojavile u neusmjerenim mrežama.
Ostaje još da opišemo način kako će se provesti implementacija opsanog modela. [1]

Prvo je potrebno uvesti postojeći Barbasi–Albert model, koji ćemo naknadno prevesti u usmjereni graf. Osnovna ideja jeste da da se usmjeravanje vrši nasumičnom orijentacijom svake strukturne grane. Za svaku ivicu $\{u, v\}$ generisanu BA modelom, smjer $u \to v$ ili $v \to u$ bira se sa vjerovatnoćom $p = 0.5$. Ovakav pristup rezultira rijetko povezanim usmjerenim grafom koji zadržava fiksni broj sinaptičkih veza, ali uvodi funkcionalnu asimetriju neophodnu za biološku simulaciju.
Zašto rijetko usmjereni graf?
Odabir rijetko povezane topologije ($m \ll N$) namjeran je istraživački postupak. Ovakva konfiguracija minimizira redundantnost veza i naglašava ulogu HUB neurona u upravljanju dinamikom mreže. Istovremeno, rijetkost grafa omogućava jasnije praćenje kaskadnih efekata pri simulaciji širenja signala, što vjernije oslikava visoko specifičnu i energetski efikasnu prirodu bioloških neuronskih krugova.[1]
Dalje je još primijenjen Daleov zakon za određivanje kako će čvor da se ponaša u mreži, o čemu će biti govora nešto kasnije.
Svakoj usmjerenoj vezi dodjeljuje se težina u skladu sa tipom izvornog neurona: ekscitatorne veze imaju pozitivne vrijednosti, dok inhibitorne imaju negativne, što omogućava simulaciju pojačanja i smanjenja signala kroz mrežu.
Na opisani način, Barabási–Albert model u ovom radu ne predstavlja doslovan opis neuronske mreže, već fleksibilan matematički okvir koji se, uz minimalne i biološki opravdane modifikacije, prilagođava složenoj prirodi neuronskih sistema. Iako nasumična orijentacija grana blago narušava čistu skalno-invarijantnu raspodjelu ulaznog i izlaznog stepena pojedinačno, ukupni stepen čvorova zadržava karakteristike BA modela, što je dovoljno za identifikaciju hub-neurona i analizu otpornosti mreže.

Neurobiološka interpretacija mehanizma preferencijalnog povezivanja

Iako je BA model primarno matematički konstrukt, on intuitivno odražava princip **sinaptičke plastičnosti**. U biološkom kontekstu, "preferencijalno povezivanje" možemo interpretirati kroz procese učenja i adaptacije:

- **Aktivnost-ovisno jačanje:** Neuroni koji su već dobro povezani (hubovi) češće učestvuju u prenosu signala. Prema Hebbovom principu ("neuroni koji se skupa aktiviraju, skupa se i povezuju"), takva aktivnost privlači nove sinaptičke veze, čime se njihova uloga u mreži dodatno pojačava.
- **Efikasnost resursa:** Formiranje hubova omogućava mreži da postigne kratke komunikacijske puteve uz minimalan broj dugih veza, što je ključno za energetsku efikasnost mozga.

Kombinacija ovih faktora stvara heterogenu strukturu koja spontano favorizuje važne puteve prenosa informacija. [1]

Time BA model prestaje biti samo geometrijski opis i postaje dinamički okvir koji omogućava simulaciju osnovnih principa neurobiološke organizacije, što će biti ključno za analizu otpornosti mreže u nastavku rada.

3.3 Biološka validacija težina: Daleov zakon

Jedan od ključnih principa organizacije korteksa sisara je tzv. **Daleov zakon** (engl. *Dale's Principle*), koji u modernoj neuronauci sugeriše da neuronska populacija održava stabilan balans između ekscitacije i inhibicije (E/I balans). [5]

U većini bioloških mreža, približno 80% neurona su ekscitatorni (obično glutamatergični), dok su preostalih 20% inhibitorni (GABA-ergični).
Ovakav omjer nije slučajan; on omogućava mreži da ostane u "kritičnom" stanju – dovoljno aktivna da prenosi informacije, ali dovoljno potisnuta da ne upadne u stanje hipereksitacije ili epileptiformne aktivnosti. [5]

U ovom modelu, težine w_{ij} se ne dodjeljuju iz proste uniformne raspodjele na cijelom intervalu $[-1, 1]$. Umjesto toga, svakom neuronu se pri generisanju dodjeljuje fiksni funkcionalni identitet:

- 80% veza dobija pozitivne težine $w \in [0.1, 1.0]$, simulirajući ekscitaciju.
- 20% veza dobija negativne težine $w \in [-1.0, -0.1]$, simulirajući inhibiciju.

Ovaj balans direktno utiče na dinamičku stabilnost sistema, što će biti demonstrirano u fazi simulacije propagacije signala.

3.4 Metrike strukturalne analize i identifikacija ključnih čvorova

Nakon što smo generisali mrežu zasnovanu na Barabási–Albert modelu, potrebno je kvantifikovati ulogu svakog pojedinačnog neurona unutar sistema. U teoriji grafova, to postižemo primjenom metrika centralnosti, koje nam omogućavaju da identifikujemo "hub" neurone i kritične tačke za protok informacija.

Centralnost po stepenu (Degree Centrality)
Stepen čvora predstavlja najjednostavniju, ali izuzetno važnu meru lokalne povezanosti. U usmjerenom grafu razlikujemo:

- Ulazni stepen (k_{in}): Broj sinapsi koje dovode signal do neurona.
- Izlazni stepen (k_{out}): Broj sinapsi preko kojih neuron šalje signal drugima.

U kontekstu BA modela, neuroni s visokim ukupnim stepenom $k = k_{in} + k_{out}$ nazivaju se hubovima. Oni služe kao glavni distributeri informacija u mreži. [4]

Centralnost posredovanja (Betweenness Centrality)
Dok stepen čvora mjeri lokalnu važnost, centralnost posredovanja mjeri globalnu važnost neurona u komunikaciji između udaljenih dijelova mreže. Formalno se definiše kao omjer najkraćih puteva između svih parova čvorova koji prolaze kroz posmatrani čvor v:

$$C_B(v) = \sum_{s \neq v \neq t} \frac{\sigma_{st}(v)}{\sigma_{st}}$$

gdje je σ_{st} ukupan broj najkraćih puteva od čvora s do čvora t, a $\sigma_{st}(v)$ broj onih koji prolaze kroz v. [4]
Neuroni s visokom vrijednošću ove metrike su "mostovi" u mreži; njihov gubitak može dovesti do fragmentacije mreže i prekida komunikacije između funkcionalnih modula. U implementaciji se koristi normalizovana verzija betweenness centralnosti, kako bi vrijednosti bile uporedive nezavisno od veličine mreže.

Koeficijent klasterisanja (Clustering Coefficient)
Ova metrika mjeri nivo lokalne kohezije u mreži, odnosno vjerovatnoću da su dva susjeda nekog čvora i sami međusobno povezani, formirajući trougao. Za čvor i sa stepenom k_i, lokalni koeficijent klasterisanja definiše se kao:

$$C_i = \frac{2e_i}{k_i(k_i - 1)}$$

gdje e_i predstavlja broj stvarnih veza između susjeda čvora i. U biološkom smislu, visok koeficijent klasterisanja ukazuje na postojanje lokalnih neuronskih krugova koji vrše specijalizovanu i redundantnu obradu informacija. S obzirom na to da klasterisanje po definiciji zahtijeva trijadičku zatvorenost, u radu se izračunava prosječna vrijednost ovog koeficijenta ($\langle C \rangle$) na neusmjerenoj projekciji grafa, čime se vrši procjena ukupne "isprepletenosti" neuronske arhitekture. Ovakav pristup je opravdan pošto standardna definicija klasterisanja u biološkim mrežama reflektuje lokalnu strukturnu zatvorenost, a ne smjer prenosa signala. [8]

Detekcija zajednica i modularnost

Biološki neuronski sistemi su visoko modularni, organizovani u funkcionalne klastere koji omogućavaju efikasnu segregaciju procesa. Za identifikaciju takvih grupa u modelu je korišten *Greedy Modularity* algoritam (Clauset-Newman-Moore), koji particioniše mrežu u disjunktne zajednice čvorova. Algoritam maksimizira metriku modularnosti Q, koja mjeri razliku između stvarne gustine veza unutar zajednica i očekivane gustine u nasumičnoj mreži:

$$Q = \frac{1}{2m} \sum_{ij} \left(a_{ij} - \frac{k_i k_j}{2m} \right) \delta(c_i, c_j)$$

gdje m predstavlja ukupan broj grana, a_{ij} element matrice susjedstva.

Interesantno je primijetiti da se ovdje pojavljuje u formuli Kroneckerov simbol $\delta(c_i, c_j)$. U ovom kontekstu, on ima vrijednost 1 ako čvorovi i i j pripadaju istoj zajednici. Visoka modularnost omogućava neuronskom sistemu paralelnu obradu informacija bez neželjene interferencije između različitih funkcionalnih modula, što je u kodu potvrđeno detekcijom specifičnih grupacija neurona unutar generisanog grafa.

3.5 Matrica susjedstva neuronske mreže

Matrica susjedstva omogućava kompaktan zapis kompletne topologije mreže i predstavlja osnovu za numeričku analizu strukture i dinamike neuronskog sistema.

Neka je neuronska mreža modelirana kao usmjereni težinski graf $(X, \mathcal{R}, f)$ sa $|X| = N$ neurona. Tada se struktura mreže može predstaviti matricom susjedstva

$$A = [a_{ij}] \in \mathbb{R}^{N \times N},$$

čiji su elementi definisani kao:

$$a_{ij} = \begin{cases} w_{ij}, & \text{ako postoji sinaptička veza } (x_i, x_j) \in \mathcal{R}, \\ 0, & \text{u suprotnom.} \end{cases}$$

Redovi matrice A odgovaraju presinaptičkim neuronima (izvor signala), dok kolone predstavljaju postsinaptičke neurone (cilj signala), čime se eksplicitno kodira usmjerenost mreže. [6]

Na osnovu matrice susjedstva mogu se direktno izračunati osnovne strukturalne metrike:

$$k_i^{in} = \sum_j a_{ji}, \qquad k_i^{out} = \sum_j a_{ij}, \qquad k_i = k_i^{in} + k_i^{out},$$

gdje k_i^{in} predstavlja ulazni stepen, k_i^{out} izlazni stepen, a k_i ukupni stepen čvora i. Ove vrijednosti služe za identifikaciju ključnih čvorova (hubova) i kvantifikaciju raspodjele povezanosti unutar mreže.

Matrica susjedstva takođe je osnova za dinamičke modele aktivnosti mreže, omogućavajući simulaciju širenja signala, aktivacije i inhibicije kroz mrežu.

3.6 Implementacija modela i numerički rezultati

Za potrebe istraživanja, implementiran je računarski model u programskom jeziku **Python**, koristeći biblioteku `NetworkX`. Model generiše mrežu od $N = 300$ neurona (čvorova), pri čemu je parametar rasta postavljen na $m = 3$, što očekujemo da će rezultirati brojem veza od oko 891 (tačnije $m(N - m)$).
Ispod se nalazi primijenjeni programski kod za generisanje mreže:

```
G_undirected = nx.barabasi_albert_graph(n=N, m=m, seed=42)
G = nx.DiGraph()
G.add_nodes_from(G_undirected.nodes())
for n in G.nodes():
    G.nodes[n]['type'] = 'E' if np.random.rand() < 0.8 else 'I'
for u, v in G_undirected.edges():
    if np.random.rand() < 0.5:
        src, dst = u, v
    else:
        src, dst = v, u
    tip_izvora = G.nodes[src]['type']
    if tip_izvora == 'E':
        tezina = np.random.uniform(0.1, 1.0)
    else:
        tezina = np.random.uniform(-1.0, -0.1)
    G.add_edge(src, dst, weight=tezina)
```

Nakon generisanja topologije, primjenjuju se funkcije za ekstrakciju strukturalnih parametara.
Poseban fokus je stavljen na **Betweenness centralnost** za identifikaciju ključnih komunikacijskih čvorova, dok se kroz **Greedy Modularity** algoritam analizira grupisanje neurona u funkcionalne module.
Dobijeni numerički podaci poslužili su kao osnova za vizualizacije prikazane u nastavku. Cijeli programski kod, koji uključuje sve iznad pomenute proračune, može se pogledati u posljednjoj sekciji.

3.7 Vizualizacija i interpretacija rezultata

Nakon izvršene simulacije i ekstrakcije parametara, generisana je mreža koja se sastoji od $N = 300$ čvorova i $L = 891$ usmjerenih veza. Dobijeni rezultati potvrđuju teorijska predviđanja Barabási–Albertovog modela u kontekstu neuronske arhitekture.
Analiza distribucije stepena čvorova
Na histogramu ispod prikazana je distribucija stepena čvorova $P(k)$.

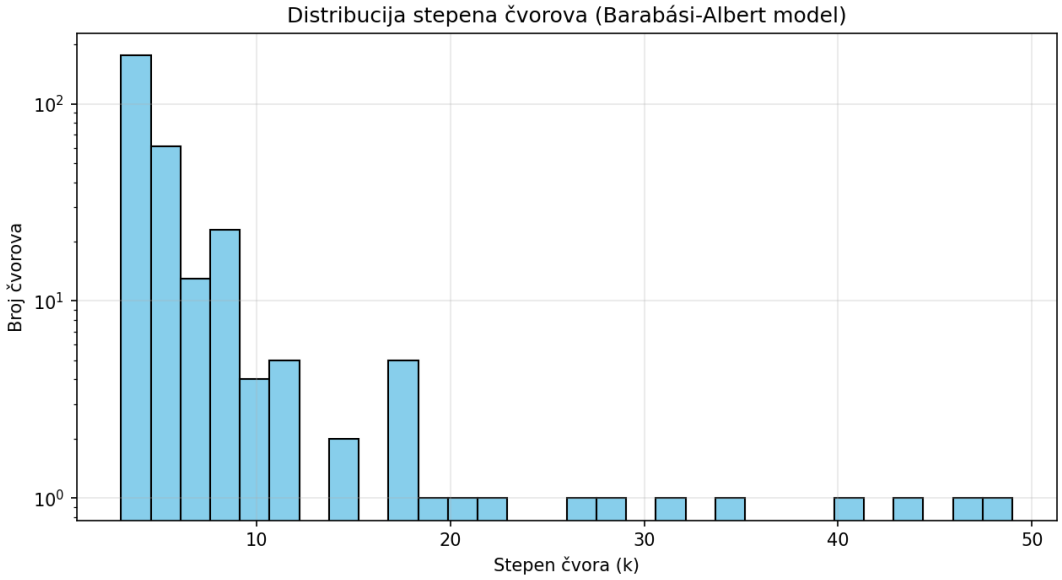

Primjećujemo sledeće ključne karakteristike:

- **Zakon snage (Power-law):** Histogram jasno pokazuje da većina neurona ima veoma mali broj veza (minimalni stepen $k = 3$), dok mali broj čvorova poseduje ekstremno visoku povezanost. Ovakav oblik distribucije na logaritamskoj skali (y-osa) potvrđuje **skalno-invarijantnu** prirodu mreže.
- **Identifikacija HUB neurona:** Najistaknutiji element mreže je čvor **4**, koji sa stepenom $k = 49$ predstavlja dominantni strukturalni hub. Njegov stepen je više od 16 puta veći od stepena perifernih čvorova (poput čvora 299 čiji je $k = 3$), što ga postavlja u centar komunikacionih puteva.

U tabeli ispod sumirani su ključni topološki parametri dobijeni nakon generisanja mreže. I ovdje se odmah može uočiti da se čvor 4 izdvaja kao apsolutni strukturalni i funkcionalni centar sistema, dominirajući i po broju veza i po kontroli protoka informacija kroz mrežu.

Tablica 1: Numerički rezultati strukturalne analize generisane mreže

Parametar	**Vrijednost**
Ukupan broj neurona (N)	300
Ukupan broj usmjerenih sinapsi (L)	891
Maksimalni stepen čvora (k_{max})	49 (Čvor 4)
Minimalni stepen čvora (k_{min})	3 (Čvor 299)
Maksimalna *Betweenness* centralnost	0,1982 (Čvor 4)
Prosječni koeficijent klasterisanja	0,0728
Broj detektovanih zajednica (modularnost)	10

Interpretacija mjera centralnosti i klasterisanja
Numerička analiza *Betweenness* centralnosti i koeficijenta klasterisanja pruža dublji uvid u funkcionalni kapacitet mreže:

- **Kritične tačke komunikacije:** Čvor **4** također posjeduje najvišu vrijednost *Betweenness* centralnosti od **0.1982**. To znači da skoro 20% svih najkraćih puteva komunikacije u cijelom sistemu prolazi kroz ovaj jedan neuron, što ga čini kritičnom tačkom za očuvanje funkcionalnosti mreže.
- **Lokalna povezanost:** Prosječni koeficijent klasterisanja iznosi **0.0728**. Ova relativno niska vrijednost sugeriše da mreža nije organizovana u izolovane lokalne grupe (klike), već je dizajnirana za efikasnu globalnu transmisiju signala preko hubova, što je tipično za sisteme koji optimizuju brzinu prenosa uz minimalan broj veza.

Modularna organizacija
Algoritam za detekciju zajednica identifikovao je **10 funkcionalnih modula (zajednica)**. U biološkom kontekstu, ovo ukazuje na to da se unutar globalne skalno-invarijantne strukture spontano formiraju podgrupe neurona koji su zaduženi za specifične zadatke (funkcionalna segregacija).
Ovakva organizacija omogućava mozgu da istovremeno vrši specijalizovanu obradu u modulima i brzu integraciju tih podataka preko glavnog huba (čvor 4).

3.8 Vizualizacija topološke strukture

Kako bi se omogućila intuitivna analiza topologije mreže, kreirana je vizualizacija koja prikazuje čvorove i njihove međusobne veze u dvodimenzionalnom prostoru. Ovaj graf omogućava identifikaciju ključnih čvorova, kao i uvid u hijerarhiju i protok informacija kroz mrežu.

Kategorizacija čvorova po stepenu:

- **Hub neuroni (Crvena boja):** Čvorovi sa gornjih 5% stepena, ključni za integritet mreže i glavni distributeri informacija.
- **Srednji neuroni (Žuta boja):** Čvorovi čiji stepen spada u opseg od 5% do 20%, služe kao posrednici između hubova i perifernih čvorova.
- **Periferni neuroni (Plava boja):** Čine većinu mreže (80%), sa malim brojem veza, simulirajući lokalne senzorske ili efektorske neurone.

Formalna veza vizualizacije sa matematičkim modelom:
Kako bi se stavio naglasak na bitnost i vrstu pojedinih čvorova u generisanom grafu, isti su osim različitim bojama predstavljeni i različitim veličinama na ovom grafikonu.
Ova ideja provedena je na ispod opisani način. Neka je k_i stepen čvora i. Veličina čvora u grafičkom prikazu proporcionalna je stepenu:

$$s_i \propto k_i,$$

Smjer prijenosa signala između čvorova prikazan je strelicama na granama. U ovoj implementaciji boja grana ostaje uniformna, a heterogenost težina odražava se kroz analizu distribucije stepena i centralnosti.

Opis vizualnog prikaza
Pozicije čvorova određene su algoritmom `spring_layout`, koji minimizira preklapanje grana i osigurava preglednu prezentaciju mreže. Veličina čvorova proporcionalna stepenu omogućava brzo prepoznavanje hubova, dok boje čvorova jasno diferenciraju kategorije. Strelice naglašavaju usmjerenost mreže i tok informacija.
Za vizualizaciju korišten je dio Python koda koji generiše raspored čvorova, postavlja veličine proporcionalno stepenu i boje prema kategoriji:

```
# Sortiranje po stepenu
sorted_nodes = sorted(G.degree, key=lambda x: x[1], reverse=True)
# Kategorizacija (hub, srednji, periferni)
hubs = [n for n, _ in sorted_nodes[:int(0.05 * N)]]
mid = [n for n, _ in sorted_nodes[int(0.05*N):int(0.20*N)]]
# Veličina čvorova proporcionalna stepenu
node_sizes = [G.degree(n) * 15 for n in G.nodes()]

pos = nx.spring_layout(G, seed=42)
```

Dobiveni rezultati prikazani su na slici ispod:

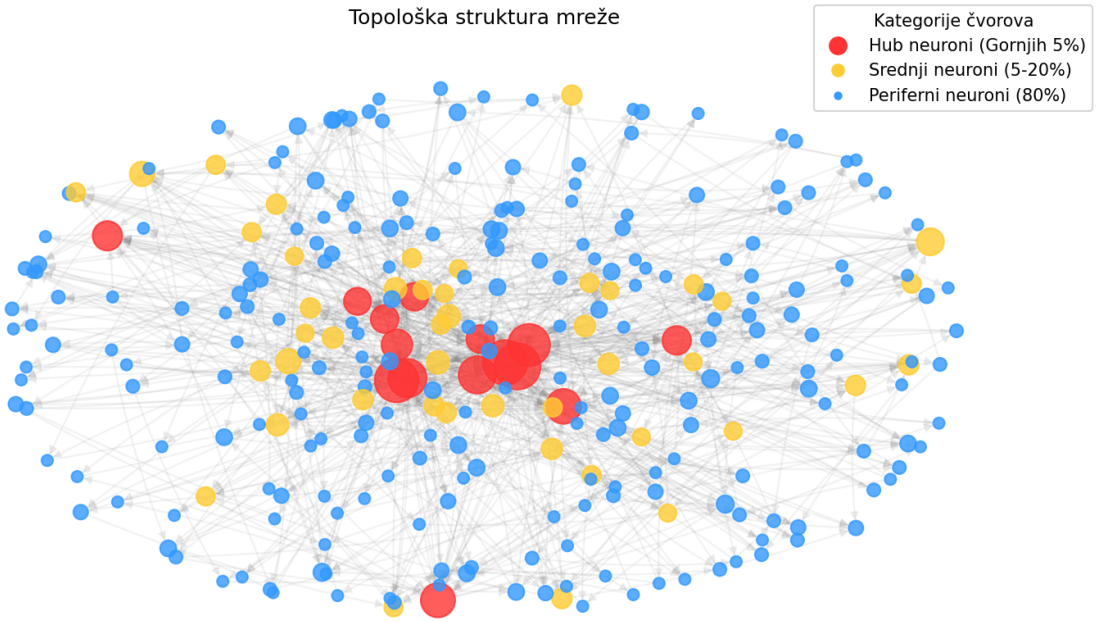

Interpretacija rezultata

Vizualizacija na slici nedvosmisleno potvrđuje heterogenu, *scale-free* prirodu generisanog modela. Jasno je uočljiva visoka koncentracija veza oko malog broja crvenih hub-neurona, dok plava periferija dominira prostorom, ali sa niskom individualnom povezanošću. Ovakva struktura omogućava ekstremno efikasan prenos informacija uz niske metaboličke troškove (mali broj ukupnih veza). Međutim, ona takođe ukazuje na specifičnu ranjivost: disfunkcija centralnih hubova (čvor 4) može dovesti do trenutne fragmentacije mreže i potpunog gubitka funkcionalne integracije, što je ključno za razumijevanje neurodegenerativnih procesa.

4 Faza 2: Dinamička simulacija propagacije signala

U ovoj fazi, strukturni usmjereni težinski graf iz faze 1 biće pretvoren u dinamički sistem simulacijom širenja aktivnosti kroz mrežu tokom diskretnog vremena t. Cilj je vizualizovati kako topološka svojstva, poput čvorišta (hubova) i zajednica, direktno utiču na efikasnost i obrasce toka informacija. Prije početka implementacije, jako je bitno reći da model koji će biti izgrađen u ovoj fazi rada vjerno opisuje ključne funkcionalne aspekte propagacije signala u neuronskim mrežama i na taj način omogućava realističnu analizu uticaja topoloških karakteristika mreže, poput čvorišta i zajednica, na obrasce širenja pobude i stabilnost ukupne dinamike.
Ipak, model ne uključuje detaljnu biofizičku simulaciju metaboličkih i elektrohemijskih procesa na nivou pojedinačnog neurona. Ovi aspekti su svjesno apstrahovani jer ne utiču direktno na razmatrani fenomen i nisu od presudnog značaja za analizu mrežnog nivoa dinamike.

4.1 Teorijski i biološki okvir dinamičke simulacije

Prelazak sa statičke topologije na dinamičku simulaciju omogućava istraživanje osnovne paradigme neuronauke: odnosa strukture i funkcije. U ovom modelu, struktura je definisana skalno-invarijantnom mrežom, dok funkciju predstavlja propagacija električnog impulsa. Kako bi simulacija bila biološki vjerodostojna, mehanizam širenja signala temelji se na četiri temeljna principa koji osiguravaju stabilnost i **ekscitatorno-inhibitorni (E/I) balans** sistema. [1]

4.1.1 Sumacija i integracija signala (Prag θ)

Biološki neuroni vrše prostornu i vremensku sumaciju svih dolaznih signala koje primaju preko svojih dendrita. Neuron se aktivira i generiše impuls tek kada kumulativni efekat svih stimulacija nadmaši specifični prag ekscitabilnosti (θ). [1]
Ovaj princip je implementiran u kodu kroz uslov:

```
abs(neto) > pocetni_theta
```

i omogućava mreži da filtrira pozadinski šum i reaguje isključivo na relevantne obrasce aktivnosti.

4.1.2 Refraktorni period i metabolički oporavak

Nakon emisije impulsa, neuron ulazi u fazu privremene neosjetljivosti, poznatu kao refraktorni period. Tokom ovog vremena, neuron obnavlja ionski balans i metaboličku energiju. U simulaciji je ovo modelirano kroz varijablu `energija`; neuron koji je upravo "okinuo" ne može ponovo učestvovati u prijenosu dok se njegova energetska vrijednost ne vrati iznad definisane granice. Ovaj mehanizam sprečava nekontrolisane oscilacije i štiti hubove od informacionog preopterećenja. [4]

Sa biološkog aspekta, refraktorni period omogućava precizno vremensko kodiranje akcijskih potencijala, sprečava prebrzu reaktivaciju neurona i doprinosi stabilnosti mrežnog ritma. Osim toga, on podržava funkcionalnu segregaciju signala, osiguravajući da impulsi putuju diskretno i omogućavaju sinaptičkoj plastičnosti da djeluje na pravilno tempirane obrasce aktivnosti.

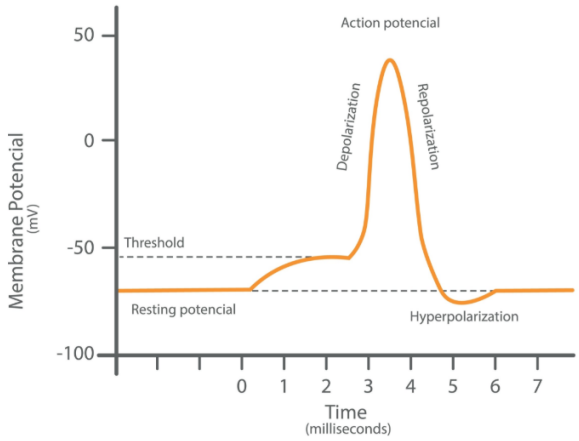

Slika 1: Ilustracija refraktornog perioda neurona.

4.1.3 Disipacija i slabljenje signala

Prenos signala kroz biološko tkivo nije savršeno efikasan. Uslijed fiziološkog otpora, intenzitet impulsa postepeno opada sa udaljenošću od izvora. Fenomen disipacije osigurava da aktivnost ostane lokalizovana ili fokusirana unutar funkcionalnih modula, sprečavajući da se svaki slabi impuls proširi na cijelu mrežu, što bi dovelo do nefunkcionalne prezasićenosti sistema. [1]

U našoj implementaciji, ovaj princip je direktno reflektovan u funkciji `simuliraj_dinamiku` linijom:

```
neto = suma_ulaza - disipacija
```

Ovdje se od ukupne sume ulaznih signala oduzima fiksna vrijednost `disipacija` (u našem slučaju 0.15). Time se slabi signali automatski filtriraju – ako neto signal ne premaši prag aktivacije (`pocetni_theta` = 0.35), neuron neće biti aktiviran. Na taj način, kod elegantno modelira biološki fenomen slabljenja impulsa i lokalizaciju aktivnosti unutar mreže.

4.1.4 Sinaptička plastičnost i Hebbovo učenje (Parametar η)

Jedna od najvažnijih karakteristika bioloških mreža je sposobnost prilagođavanja. Prema Hebbovom principu, efikasnost sinaptičke veze se povećava ako presinaptički neuron učestalo doprinosi aktivaciji postsinaptičkog neurona. U našem modelu, parametar `eta` (learning rate) simulira ovaj proces jačanjem težina onih veza koje su aktivno učestvovale u prijenosu, čime se fiksna topologija pretvara u adaptivni sistem sposoban za optimizaciju protoka informacija. [1]

4.2 Matematički model dinamike

U ovoj fazi, strukturni graf se transformiše u dinamički sistem, gdje svaki čvor funkcioniše kao aktivni neuron. Model formalizuje ponašanje neurona u diskretnim vremenskim koracima $t = 0, 1, 2, \ldots$.

4.2.1 Stanje neurona

Neka je $s_i(t) \in \{-1, 0, 1\}$ stanje neurona i u trenutku t:

- $s_i(t) = 1$ — ekscitacija,
- $s_i(t) = -1$ — inhibicija,
- $s_i(t) = 0$ — neaktivno stanje.

Vremenska zavisnost je ključna: stanja neurona u trenutku $t+1$ zavise isključivo od stanja u trenutku t, što osigurava konzistentnost uzročnosti.

4.2.2 Neto ulazni signal

Neto ulazni signal u neuron i u trenutku t definisan je kao:

$$S_i(t) = \sum_{j \in Pre(i)} w_{ji}(t) \cdot s_j(t) - \Delta, \tag{1}$$

gdje je:

- $w_{ji}(t)$ težina veze iz neurona j u i u trenutku t,
- Δ faktor disipacije, koji modeluje gubitak signala pri prijenosu.

U kodu je ovaj koncept implementiran linijom:

```
neto = suma_ulaza - disipacija
```

Ovim se automatski filtriraju slabi signali: ukoliko neto signal ne pređe prag aktivacije (`pocetni_theta`), neuron neće biti aktiviran.

4.2.3 Pravilo aktivacije

Neuron i prelazi u aktivno stanje u trenutku $t+1$ ako neto signal premaši prag aktivacije i ako je energija neurona dovoljna:

$$s_i(t+1) = \begin{cases} \text{sgn}(S_i(t)), & \text{ako } |S_i(t)| > \theta \text{ i } E_i(t) > E_{min}, \\ 0, & \text{u suprotnom.} \end{cases} \tag{2}$$

4.2.4 Dinamika metaboličke energije

U trenutnoj implementaciji, energija neurona $E_i(t)$ modeluje refraktorni period:

- Neuron koji aktivira ima energiju postavljenu na 0.0:

```
energija[i] = 0.0
```

- Energija se ne povećava automatski u svakom koraku; aktivacija neurona je ograničena dok se energija ne vrati iznad definisane granice.

Ovaj princip osigurava da neuron ne može pucati u uzastopnim koracima i sprečava preopterećenje hubova. U narednoj sekciji je objašnjeno zašto se autorica rada odlučila na ovaj način modeliranja metaboličke energije.

4.2.5 Specifičnost energetskog modela i cilj simulacije

Iako u biološkim sistemima neuroni prolaze kroz proces repolarizacije i metaboličkog oporavka koji im omogućava višekratno okidanje, u ovoj implementaciji energija neurona se nakon prve aktivacije trajno postavlja na vrijednost 0.0. Ova namjerna simplifikacija modela uvedena je iz dva ključna razloga:

- **Mapiranje primarne propagacije:** Primarni cilj istraživanja je analiza *dosegljivosti* (engl. *reachability*) unutar mreže. Fiksiranjem energije na nulu, eliminišu se povratne petlje i oscilacije, što omogućava precizno praćenje "primarnog talasa" informacije od izvora do krajnje tačke na periferiji.
- **Topološka diskriminacija:** Ovakav pristup jasnije ističe razliku u efikasnosti između hubova i perifernih čvorova. Rezultat simulacije direktno pokazuje koliki dio mrežnog prostora jedan impuls može aktivirati isključivo zahvaljujući strukturnoj poziciji početnog neurona.

Time se simulacija transformiše iz modela kontinuirane aktivnosti u model **jednokratne propagacije signala**, što je matematički pogodnije za kvantifikaciju efikasnosti Barabási-Albert topologije.

4.2.6 Hebbovo učenje

U kodu je Hebbov princip pojednostavljen:

$$w_{ji}(t+1) = w_{ji}(t) + \eta, \tag{3}$$

ako je veza aktivno učestvovala u prijenosu signala. Težina se zatim ograničava na interval $[w_{\min}, w_{\max}]$ radi biološke i numeričke stabilnosti. Ovo simulira jačanje sinapsi koje aktivno prenose signal, bez eksplicitnog množenja sa stanjima neurona. [4]

4.2.7 Diskretna simulacija i inicijalna stimulacija

- Simulacija se odvija u diskretnim koracima t.
- Inicijalno se aktivira jedan ili više neurona kako bi se pokrenulo širenje signala.
- **Slučajevi stimulacije:**
  1. **Hub:** aktivira se čvor sa najvećim stepenom povezanosti, očekuje se brzo i široko širenje signala.
  2. **Periferija:** aktivira se čvor sa niskim stepenom povezanosti, signal često zamire nakon nekoliko koraka.
- U svakom koraku se prate stanja neurona $s_i(t)$, energija $E_i(t)$ i težine $w_{ji}(t)$.
- Aktivne sinaptičke veze se pamte radi vizualizacije širenja impulsa.

4.2.8 Napomena o stabilnosti

Ograničenje težina i kontrola energije zajedno sprječavaju numeričku nestabilnost i modeluju biološke restrikcije: neuron ne može pucati u svakom koraku, a sinaptičke veze ne mogu rasti beskonačno, čime mreža ostaje funkcionalna i adaptivna.

4.2.9 Asinhrona aktivacija

Neuronska aktivacija je efektivno asinhrona unutar diskretnog koraka: neuron koji je već aktivan u t ne može biti ponovno aktiviran u istom koraku. Time se izbjegavaju nerealne oscilacije i povratne petlje.

4.2.10 Kriterij zaustavljanja simulacije

Simulacija se prekida ako mreža uđe u potpuno pasivno stanje:

$$\sum_i |s_i(t)| = 0,$$

nakon inicijalne tranzijentne faze, što simulira prirodno izumiranje signala.

4.2.11 Parametrizacija modela

Parametar	Simbol	Vrijednost	Opis
Prag aktivacije	θ	0.35	Osjetljivost neurona na ulazne signale.
Faktor disipacije	Δ	0.15	Gubitak jačine impulsa tokom prenosa.
Stopa učenja	η	0.08	Fiksno jačanje aktivnih sinapsi.
Oporavak energije	E_{min}	0.85	Granica energija neurona za aktivaciju.
Granice težina	$[w_{min}, w_{max}]$	$[-2, 2]$	Ograničenje sinaptičkih težina.

Tablica 2: Parametri korišteni u dinamičkoj simulaciji, u skladu sa kodom.

4.3 Implementacija dinamike

Funkcija `simuliraj_dinamiku` direktno implementira matematički model. Glavni koraci uključuju inicijalizaciju, proračun neto signala, filtriranje kroz prag aktivacije i energiju, te modifikaciju sinaptičkih težina. Ispod je prikazan kod u svojim osnovnim linijama:

```
# Skraćeni prikaz logike unutar vremenske petlje
for t in range(koraci):
    nova_stanja = {n: 0 for n in G.nodes()}

    for i in G.nodes():
        if stanja[i] != 0: continue  # Neuron je već okinuo (refraktornost)

        suma_ulaza = sum(tezin_kopija[(j, i)] * stanja[j] for j in G.predecessors(i))
        neto = suma_ulaza - disipacija

        # Provjera energetskog praga i praga aktivacije
        if energija[i] > 0.85 and abs(neto) > pocetni_theta:
            nova_stanja[i] = 1 if neto > 0 else -1
            energija[i] = 0.0  # Pražnjenje energije

            # Hebbovo jačanje aktivnih veza
            for j in G.predecessors(i):
                if stanja[j] != 0:
                    tezin_kopija[(j, i)] += eta
                    tezin_kopija[(j, i)] = np.clip(tezin_kopija[(j, i)], -2.0, 2.0)
```

Ključni elementi implementacije:

1. **Sinhrona diskretna ažuriranja**
   Iako se biološki procesi odvijaju kontinuirano, kod koristi sinhroni diskretni pristup. To je postignuto uvođenjem rječnika `nova_stanja`. Unutar jednog vremenskog koraka t, svi neuroni donose odluku o aktivaciji isključivo na osnovu stanja okoline iz koraka $t-1$. Time se izbjegava *race condition*, gdje bi aktivacija jednog neurona trenutno uticala na susjeda u istom ciklusu, što osigurava stabilnost simulacije.

2. **Efikasnost pretrage grafa**
   Umjesto množenja punih matrica susjedstva (što bi za 300 čvorova bilo neefikasno jer je većina veza nula), kod koristi topološku snagu biblioteke `networkx`. Funkcija `G.predecessors(i)` direktno pristupa samo onim čvorovima koji šalju signal neuronu i, što značajno ubrzava simulaciju i fokusira resurse samo na postojeće sinaptičke veze.

3. **Upravljanje istorijom i vizualizacijom**
   Logika koda ne prati samo trenutno stanje, već gradi objekat `istorija = []`. Svaki element ove liste je snimak (*snapshot*) kompletnog stanja mreže u određenom trenutku. Ovaj pristup omogućava:

   - **Post-procesiranje:** Analizu dometa signala nakon što se simulacija završi.
   - **Interpolaciju za animaciju:** Kreiranje glatkih prelaza između diskretnih koraka pomoću `FuncAnimation`.

4. **Algoritamski kriterij zaustavljanja**
   Program uključuje logički osigurač koji prekida izvršavanje čim mrežna aktivnost zamre (`sum(abs(s)) == 0`). Ovo sprječava nepotrebno trošenje procesorskog vremena na simulaciju statične mreže bez impulsa, što je ključno kod masovnih simulacija.

5. **Numerička saturacija (Guardrails)**
   Hebbovo učenje u kodu implementirano je sa ugrađenim sigurnosnim granicama pomoću `np.clip`. Ovdje programska logika služi kao kontrolor koji sprječava da težine postanu beskonačno velike, čime se izbjegavaju numeričke greške (*overflow*) i nerealni rezultati u kasnijim koracima simulacije.

4.4 Scenariji simulacije i biološka interpretacija

Simulacije se izvode kroz dva osnovna scenarija koji se razlikuju isključivo po izboru početno aktiviranog neurona. Na ovaj način izoluje se uticaj topološke uloge neurona na globalnu dinamiku mreže, dok svi ostali parametri i pravila evolucije ostaju nepromijenjeni.
U prvom scenariju aktivira se neuron sa visokim stepenom povezanosti (hub-neuron), što modeluje situaciju u kojoj signal potiče iz centralno pozicionirane neuronske jedinice sa velikim brojem sinaptičkih veza. Ovaj scenarij je relevantan za procese u kojima ključne neuronske strukture iniciraju i distribuiraju informaciju kroz mrežu.
U drugom scenariju inicijalna aktivacija se dodjeljuje neuronu sa malim stepenom povezanosti (periferni neuron). Ovaj slučaj predstavlja lokalizovani podražaj koji se javlja u rubnim dijelovima mreže i omogućava poređenje efikasnosti širenja signala u odnosu na hub-aktivaciju.

Poređenjem ova dva scenarija analizira se kako topološka centralnost početnog neurona utiče na domet, trajanje i stabilnost neuronske aktivnosti u mreži.

4.4.1 Scenarij 1: Aktivacija hub-neurona

U ovom scenariju simulacija započinje vještačkom stimulacijom čvora sa najvećim stepenom povezanosti (k_{max}), Hub-neurona. Ovaj čvor u mreži od $N = 300$ neurona djeluje kao primarni distributer informacija.

Tok simulacije i zapažanja:

- **Eksplozivna propagacija:** Nakon inicijalne aktivacije u koraku $t = 0$, signal se naglo širi kroz mrežu. Zahvaljujući visokom izlaznom stepenu (*out-degree*) Hub-neurona, impulsi se simultano distribuiraju ka velikom broju susjeda, čime se preskaču lokalne barijere.

- **Neuralna lavina:** Signal se ne širi linearno, već eksponencijalno zahvata čitave klastere neurona. Ovaj fenomen podsjeća na kritična stanja u biološkim mrežama gdje jedan snažan impuls može rekrutovati većinu dostupnih resursa mreže.

- **Hebbovo ojačanje:** Tokom propagacije, sinaptičke veze na relaciji centar-periferija se ubrzano modifikuju. Prema Hebbovom principu, korelacija između aktivnosti Hub-a i njegovih susjeda rezultira povećanjem težina ($\Delta w_{ji} > 0$), čime se formira stabilna "autoput" infrastruktura za budući prijenos signala.

Vizuelna reprezentacija (Snapshots): Vizualizacija rezultata Scenarija 1 (stimulacija huba) prikazana je kroz četiri karakteristična vremenska koraka ($t \in \{0, 2, 5, 8\}$) u seriji snapshot-ova u ispod. Veličina čvora korelira sa njegovim stepenom povezanosti, dok siva boja označava neurone u stanju mirovanja. Crveni čvorovi predstavljaju aktivne ekscitatorne neurone, dok plavi predstavljaju aktivirane inhibitorne neurone. Crvene strelice markiraju aktivne sinaptičke puteve kroz koje se signal u datom trenutku prenosi.
Na snapshotovima su jasno vidljive osnovne faze širenja signala kroz mrežu:

1. **Korak 0: Inicijalni impuls**
   Vidi se kako centralni hub-čvor "eksplodira" i šalje signal svim svojim susjedima. Ovo je trenutak $t = 0$ koji pokreće cijelu kaskadu.

2. **Korak 2: Vrhunac lavine**
   Ovo je najimpresivnija slika. Signal je zahvatio jezgru mreže. Vidi se ogroman broj strelica koje idu od centra ka periferiji. Mreža je u stanju maksimalne aktivnosti.

3. **Korak 5: Početak smirivanja**
   Broj aktivnih strelica je manji. Neki neuroni su već ušli u refraktorni period (energetski su iscrpljeni), pa se signal širi samo u rubnim dijelovima.

4. **Korak 8: Terminacija**
   Aktivnost skoro potpuno zamire. Ostala su samo dva ili tri aktivna plava (inhibitorna) neurona. Ovo pokazuje da je mreža stabilna i da ne ulazi u beskonačnu petlju, već se sama smiruje.

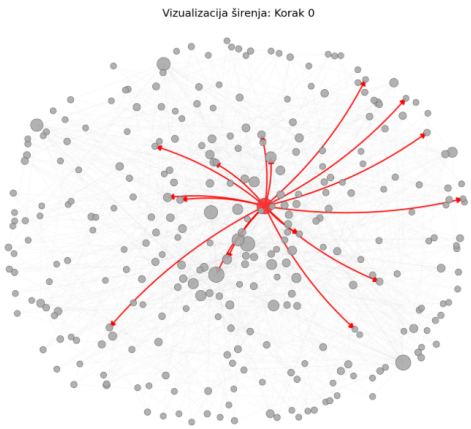

(a) Korak 0: Stimulacija hub-neurona

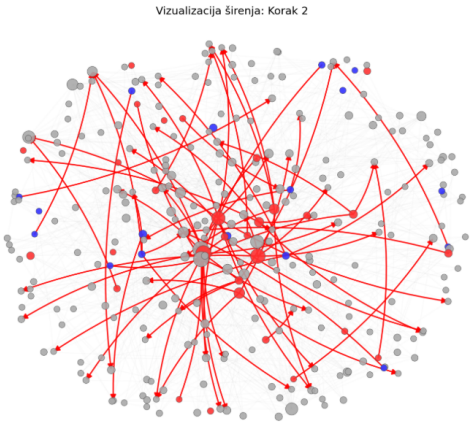

(b) Korak 2: Maksimalna neuralna lavina

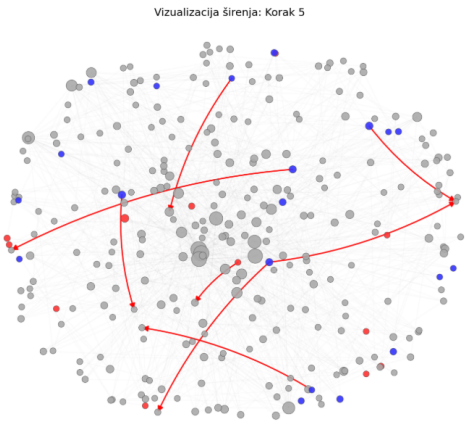

(c) Korak 5: Disipacija signala

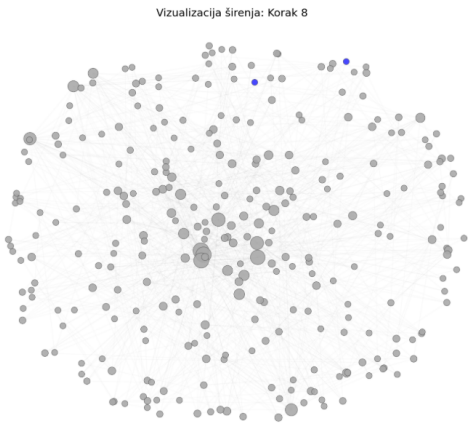

(d) Korak 8: Završetak aktivnosti

Slika 2: Hronološki prikaz širenja signala kroz mrežu iniciranog iz hub-neurona.

Biološka interpretacija i značaj: Aktivacija hub-neurona u simulaciji ima višestruke implikacije u kontekstu neuroznanosti i funkcionalne organizacije mozga:

- **Koordinacija globalnih mreža:** Hub-neuroni djeluju kao centralni distributeri informacija, povezujući različite lokalne klastere neurona. U mozgu, takve visoko povezane regije omogućavaju sinhronizaciju aktivnosti preko udaljenih dijelova korteksa i limbičkog sistema, što je ključno za brzu obradu složenih zadataka.
- **Efikasna propagacija signala:** Zahvaljujući velikom broju izlaznih veza, hub-neuroni mogu aktivirati veliki broj susjednih neurona u kratkom vremenskom intervalu. Ovo osigurava da kritične informacije (npr. senzorne ili motoričke komande) brzo stignu do svih relevantnih dijelova mreže.
- **Energetska ekonomija:** Iako hub-neuroni troše znatno više energije zbog česte i masovne aktivacije (što se u modelu vidi kroz brzi pad E_i), njihova funkcija je optimizovana za maksimalnu efikasnost u distribuciji informacija. Biološki, ovo odražava metabolizam visoko povezanih regija, koje balansiraju između brzine širenja signala i energetske potrošnje.
- **Adaptivnost i učenje:** Hub-neuroni, aktivirajući širok spektar susjeda, omogućavaju sinaptičku plastičnost kroz Hebbovo učenje. Putanje koje često prenose signal se ojačavaju, dok slabe veze slabe ili ostaju nepromijenjene. Ovo dovodi do formiranja stabilnih i funkcionalno značajnih mrežnih obrazaca, što je ekvivalent pamćenju i konsolidaciji informacija u mozgu.
- **Otpornost mreže:** Hub-aktivacija omogućava mreži da brzo reaguje na pojedinačne poremećaje. U slučaju gubitka ili inhibicije periferne aktivnosti, hub može inicirati novu propagaciju signala, održavajući funkcionalnu povezanost mreže.

Ukratko, Scenarij 1 simulira centralnu ulogu hub-neurona u mozgu: omogućava brzo i efikasno širenje informacija, stabilizuje ključne sinaptičke puteve, balansira energetsku potrošnju i osigurava adaptivnu i otpornu mrežnu dinamiku. Ova funkcionalnost je u skladu sa opažanjima u stvarnim neurološkim sistemima, uključujući talamus, prefrontalni korteks i hipokampus, gdje visoko povezane regije koordiniraju aktivnosti i olakšavaju kritične kognitivne i senzorne funkcije.

4.4.2 Scenarij 2: Aktivacija perifernog neurona

U ovom scenariju, stimulacija je započeta na čvoru sa minimalnim stepenom povezanosti ($k = 1$). Cilj ovog eksperimenta bio je ispitati da li lokalni podražaj može biti prigušen disipacijom ili će uspjeti da se propagira dalje.

Analiza očekivanja i hipoteza: U ovom dijelu simulacije dobivamo vrlo interesantan rezultat koji prati jednako interesantna biološka interpretacija. Naime, ono što intuitivno očekujemo za čvor sa malim stepenom povezanosti jeste da će njegov uticaj ostati strogo lokalizovan. Hipoteza se zasniva na pretpostavci da jedan periferni impuls neće imati dovoljno "snage" (ekscitatornog potencijala) da savlada pragove aktivacije većeg broja neurona, te da će se signal, uslijed disipacije energije, ugasiti nakon svega par koraka bez pokretanja globalne kaskade.

Ipak, rezultati simulacije (prikazani na snapshotovima ispod) demantuju ovu inicijalnu intuiciju i otkrivaju dublju kompleksnost *scale-free* topologije:

Vizuelna reprezentacija (Snapshots): Dinamika širenja signala iz periferne tačke analizirana je kroz odabrane diskretne vremenske korake, koji reprezentuju karakteristične faze evolucije sistema: početnu pobudu, ranu lokalnu propagaciju, kasnu fazu širenja te konačno gašenje aktivnosti. Ovi koraci su izabrani jer jasno ilustruju promjene u prostornoj distribuciji aktivnih i inhibicionih čvorova, kao i efekte disipacije energije u mreži.

- **Korak 0 (p00.png):** Inicijalna aktivacija zahvata samo jedan periferni čvor. Primjećuje se samo jedna aktivna sinaptička veza (crvena strelica) koja vodi ka unutrašnjosti mreže.
- **Korak 2 (p02.jpg):** Suprotno očekivanjima o brzom zamiranju, signal doseže do centralnog huba. Zbog niske vrijednosti praga aktivacije, jedan impuls je bio dovoljan da aktivira hub, što uzrokuje sekundarnu, masovnu lavinu koja zahvata gotovo cijelu mrežu.
- **Korak 5 (p05.jpg):** Aktivnost dostiže svoj plato. Iako je krenula sa periferije, mreža je sada u stanju visoke ekscitacije, slično kao u Scenariju 1.

- **Korak 9 (p09.png):** Dolazi do terminacije signala. Mreža se vraća u stanje mirovanja, ostavljajući za sobom modifikovane sinaptičke težine.

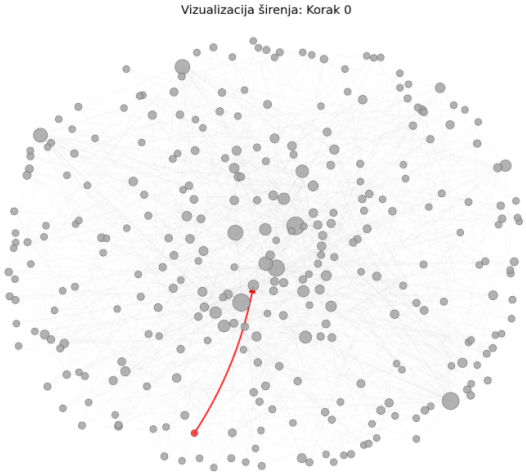

(a) Korak 0: Lokalni podražaj

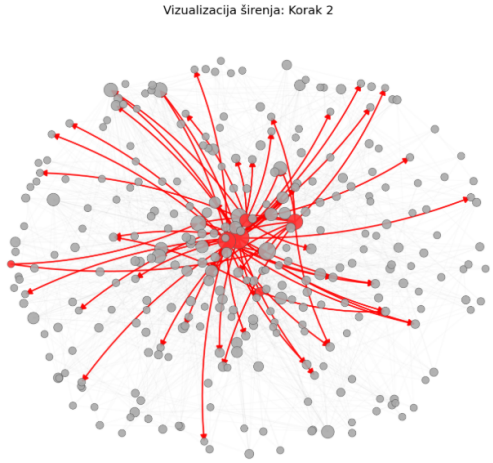

(b) Korak 2: Aktivacija huba i amplifikacija

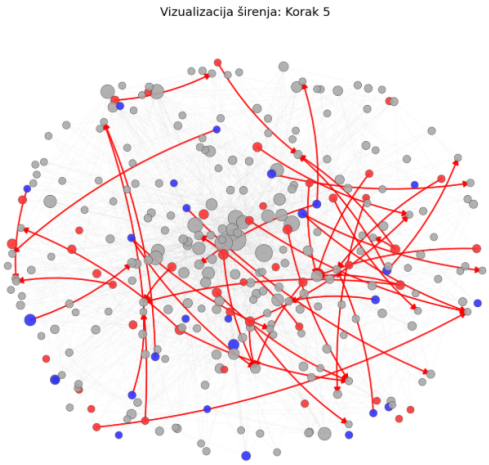

(c) Korak 5: Globalna propagacija

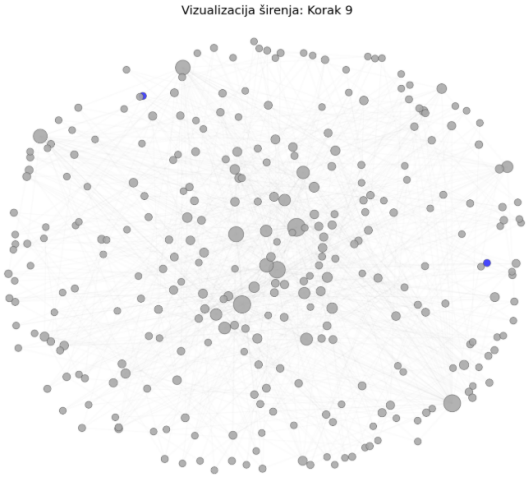

(d) Korak 9: Smirivanje mreže

Slika 3: Prikaz indirektne kaskade: periferni čvor aktivira centralni hub, pokrećući globalni odgovor mreže.

Analiza rezultata: Ovaj scenario demonstrira fenomen *"Small-world"* mreža unutar Barabási-Albert modela. Iako je izvor signala topološki beznačajan, njegova direktna povezanost sa hubom omogućila je **amplifikaciju signala**. U neuroznanosti, ovo modeluje situaciju u kojoj lokalni senzorni ulaz (npr. lagani dodir) uspijeva da aktivira talamus ili primarni korteks, čime se informacija distribuira globalno. Rezultat ukazuje na to da su *scale-free* mreže izuzetno osjetljive na lokalne perturbacije ako one imaju pristup kritičnim komunikacijskim čvorištima.[8]

Biološka interpretacija i značaj: Aktivacija perifernog neurona u našem modelu otkrila je kompleksnu ulogu neurona sa malim stepenom povezanosti:

- **Senzorni ulaz i lokalna obrada:** Periferni neuroni u biološkim sistemima često predstavljaju senzorne receptore koji detektuju lokalne promjene. Iako sami ne upravljaju mrežom, oni su ključni za unos sirovih informacija.
- **Fenomen "Small-world" okidanja:** Rezultat je pokazao da periferija nije izolovana. Zahvaljujući maloj prosječnoj distanci između čvorova, lokalni impuls može biti munjevito amplificiran. Ovo modelira situaciju u kojoj jedan specifičan podražaj (npr. oštar zvuk) trenutno mobiliše resurse cijelog mozga.

- **Funkcionalna segregacija naspram integracije:** Iako topologija omogućava segregaciju (da lokalni poslovi ostanu lokalni), naša simulacija je pokazala visoku integrisanost sistema. To ukazuje na to da su biološke mreže "podešene" da budu na ivici stabilnosti i uzbuđenja.
- **Energetska efikasnost:** Periferni neuroni troše minimalno energije, ali služe kao efikasni okidači za skuplje, visoko-povezane hubove, optimizujući tako energetski profil cijele mreže.

Ukratko, Scenarij 2 je demonstrirao da mrežna topologija može prevladati lokalnu prirodu neurona. Periferni čvorovi ne služe samo za lokalnu obradu, već i kao kritične tačke koje mogu pokrenuti globalnu kaskadu ako su adekvatno povezani sa mrežnom okosnicom (hubovima).

Poređenje scenarija i diskusija Direktno poređenje dva simulirana scenarija jasno pokazuje da izbor početno aktiviranog neurona ima presudan uticaj na dinamiku širenja signala i vremensku složenost evolucije mreže. Iako su svi ostali parametri modela identični, razlika u topološkoj centralnosti inicijalnog čvora dovodi do kvalitativno različitih režima širenja informacija.

Vrijeme izvršavanja mjereno je funkcijom `time.time()`, a rezultati su sumirani u Tabeli 3.

Parametar	**Scenario 1 (Hub)**	**Scenario 2 (Periferija)**
Početni čvor	Najveći stepen ($k_{\max}$)	Najmanji stepen ($k_{\min}$)
Vrijeme izvršavanja [s]	≈ 0.014	≈ 0.059
Tip kaskade	Trenutna "lavina"	Odložena amplifikacija
Broj koraka do vrha	Minimalan (direktan)	Veći (indirektan)

Tablica 3: Uporedni prikaz numeričkih performansi i dinamičkih karakteristika scenarija.

U Scenariju 1 (Hub), izmjereno vrijeme od $t_{\text{hub}} \approx 0.014\,\text{s}$ ukazuje na izuzetnu efikasnost širenja. Zbog visokog stepena povezanosti, hub-neuron simultano aktivira stotine susjeda, trošeći energiju sistema u svega nekoliko intenzivnih koraka. Iako je računarski intenzivan po koraku, ovaj scenario brže dostiže terminaciju jer signal nema "topoloških prepreka".

Nasuprot tome, Scenario 2 (Periferija) pokazuje neočekivano duže vrijeme izvršavanja ($t_{\text{periferija}} \approx 0.059\,\text{s}$). Ova razlika proizlazi iz fenomena latencije: perifernom impulsu je potrebno više vremenskih koraka da "pronađe" put do centralnog huba. Tek kada signal dosegne hub, dolazi do sekundarne amplifikacije (Small-world efekat). Veći broj iteracija kroz koje simulacija prolazi dok se aktivnost ne stabilizuje objašnjava veću računarsku potrošnju vremena u ovom slučaju.

Biološki posmatrano, ovi rezultati sugerišu dvije važne stvari:

1. **Efikasnost huba:** Centralne strukture mozga su optimizovane za ultra-brze, globalne odgovore.
2. **Osjetljivost periferije:** Činjenica da čak i periferija može pokrenuti globalnu kaskadu (iako sporije) dokazuje visoku integrisanost i osjetljivost neuronskih mreža. Periferija služi kao "sporiji", ali funkcionalno validan ulazni kanal koji, zahvaljujući topologiji malog svijeta, može preuzeti kontrolu nad globalnom dinamikom.

Ovim je potvrđeno da mrežna topologija ne diktira samo to *gdje* će signal otići, već i *koliko dugo* će sistemu trebati da tu informaciju integriše i procesira.

4.5 Video simulacija i interaktivni prikaz

Prije prelaska na fazu 3, postoji jedna stavka koju je jos bitno spomenuti.
Naime, primarni cilj ove faze bio je modeliranje prenosa signala kroz mrežu u realnom vremenu. Budući da je samu prirodu dinamike i "život" mreže teško u potpunosti prenijeti kroz statični format pisanog rada, prethodno prikazani snapshot-ovi su korišteni kao hronološki presjeci najvažnijih faza.
Međutim, za potpuni doživljaj kaskadnih efekata, brzine širenja signala i funkcionisanja Hebbovog učenja u realnom vremenu, simulacije su snimljene i dostupne u video formatu. Ukoliko čitalac želi vidjeti kako se topologija mreže i aktivnost neurona mijenjaju iz milisekunde u milisekundu, može pristupiti simulacijama putem sljedećih linkova:

- **Scenario 1:** Hub - aktivacija
- **Scenario 2:** Preiferija - aktivacija

Ovi snimci služe kao dopuna vizuelnoj analizi i omogućavaju uvid u kontinualni proces propagacije koji je bio osnova ovog istraživanja.

5 Faza 3: Analiza Otpornosti

U ovoj fazi analizira se strukturni integritet generisane neuronske mreže kroz postepeno uklanjanje čvorova, što simulira oštećenja ili gubitak pojedinih neurona. Cilj je istražiti kako različite strategije uklanjanja čvorova — nasumično, što imitira slučajne kvarove ili smrt neurona, i ciljno, prema čvorovima sa najvećom *Betweenness Centrality*, što simulira usmjerene napade na ključne hub-ove — utiču na globalnu povezanost mreže.
Za ocjenu očuvanja funkcionalnosti koristi se veličina *Largest Strongly Connected Component (LSCC)*, koja pokazuje koliko je mreža i dalje sposobna da prenosi informacije između svojih čvorova. Na taj način, analiza omogućava kvantifikaciju otpornosti mreže i identifikaciju njenih najranjivijih dijelova, te ilustrira inherentnu ranjivost *scale-free* topologija na ciljane napade, dok nasumični gubici imaju znatno manji uticaj na stabilnost sistema.

5.0.1 Matematički model

Cilj ovog dijela je formalno definirati metrike i pristup koji se koriste za kvantifikaciju otpornosti neuronske mreže na gubitak čvorova.

Graf i usmjerenost
Obzirom da relacija „biti povezan“ u usmjerenom grafu nije simetrična, potrebno je posebno definisati pojmove povezanosti. Formalna definicija data je u nastavku.[2]

Jaka komponenta povezanosti (SCC):
Definicija: Skup čvorova $C \subseteq V$ čini jaku komponentu povezanosti ako između bilo koja dva čvora $x_i, x_j \in C$ postoji put od x_i do x_j i put od x_j do x_i.

Ova definicija osigurava da svi čvorovi unutar komponente mogu međusobno komunicirati po definisanim smjerovima.
Najveća jako povezana komponenta (LSCC, *Largest Strongly Connected Component*) je:

$$LSCC = \arg\max_{C \subseteq V} |C|, \quad C \text{ je SCC.}$$

LSCC direktno odražava sposobnost mreže da prenosi informacije globalno, jer uključuje maksimalan skup čvorova s recipročnom usmjerenom povezanošću.

Metrika otpornosti
Otpornost mreže se mjeri relativnom veličinom LSCC nakon uklanjanja dijela čvorova:

$$f(\rho) = \frac{|LSCC(\rho)|}{N},$$

gdje je:

- $N = |V|$ - ukupan broj čvorova u originalnom grafu,
- $|LSCC(\rho)|$ - broj čvorova u najvećoj jaku povezanosti nakon uklanjanja $\rho \cdot 100\%$ čvorova,
- $\rho \in [0, 1]$ - procenat uklonjenih čvorova.

Vrijednost $f(\rho) \to 0$ označava potpunu fragmentaciju mreže i gubitak globalne komunikacije.

Strategije uklanjanja čvorova
Za analizu otpornosti razmatraju se dva scenarija:

1. **Ciljano uklanjanje (Targeted Attack):** Čvorovi se uklanjaju prema opadajućoj vrijednosti *Betweenness Centrality* (BC). Skup ciljanih čvorova σ_{target} definira se kao:

   $$\sigma_{target} = \{v \in V \mid BC(v) \text{ je najveće}\}.$$

   Očekuje se da uklanjanje ovih čvorova izaziva brzu fragmentaciju LSCC.

2. **Nasumično uklanjanje (Random Failure):** Čvorovi se biraju i uklanjaju potpuno nasumično. Ovaj scenarij simulira slučajni gubitak neurona, pri čemu LSCC opada znatno sporije nego u ciljanom napadu.[7]

Funkcija otpornosti po strategiji
Za svaku strategiju $s \in \{\text{nasumično}, \text{ciljano}\}$ definira se funkcija otpornosti:

$$f_s(\rho) = \frac{|LSCC_s(\rho)|}{N}.$$

Očekivano ponašanje funkcija je:

$$f_{\text{ciljano}}(\rho) \leq f_{\text{nasumično}}(\rho), \quad \forall \rho > 0,$$

što ilustrira veću ranjivost mreže na ciljana oštećenja ključnih čvorova.

Zaključak matematičkog modela
Ovaj formalni okvir omogućava precizno kvantificiranje otpornosti mreže, praćenje degradacije LSCC i matematičko predviđanje kritičnih tačaka fragmentacije pod različitim strategijama uklanjanja čvorova.

5.0.2 Implementacija i algoritamski pristup

Za eksperimentalnu analizu otpornosti korištena je Python funkcija `analiza_otpornosti`, koja prihvata originalni graf i simulira proces degradacije čvorova.

Parametri simulacije

- $\rho_{max} = 0.4$ (maksimalno 40% uklonjenih čvorova)
- $\Delta\rho = 0.02$ (korak u iteracijama)
- Strategije uklanjanja: *nasumično* i *ciljano* (prema *Betweenness Centrality*)

Algoritamski pristup

1. **Nasumično uklanjanje:**

```
svi_cvorovi = list(G_original.nodes())
np.random.shuffle(svi_cvorovi)
for p in koraci:
    temp_G = copy.deepcopy(G_original)
    temp_G.remove_nodes_from(svi_cvorovi[:int(p * N)])
    komp = sorted(nx.strongly_connected_components(temp_G), key=len, reverse=True)
    lscc_nasumicno.append(len(komp[0]) / N if komp else 0)
```

   Ovdje se za svaki korak uklanja određeni procenat čvorova nasumičnim odabirom, čime se modeluje neselektivno oštećenje mreže.

2. **Ciljano uklanjanje:**

```
bc_scores = nx.betweenness_centrality(G_original)
poredani_cvorovi = [n for n, v in sorted(bc_scores.items(),
                    key=lambda x: x[1], reverse=True)]
for p in koraci:
    temp_G = copy.deepcopy(G_original)
    temp_G.remove_nodes_from(poredani_cvorovi[:int(p * N)])
    komp = sorted(nx.strongly_connected_components(temp_G), key=len, reverse=True)
    lscc_ciljano.append(len(komp[0]) / N if komp else 0)
```

   Čvorovi se uklanjaju prema inicijalnom poretku centralnosti između, simulirajući ciljani napad na kritična čvorišta (hub-ove) koja drže mrežu povezanom.

Rezultati simulacije
Nakon izvršavanja algoritma, generiše se grafikon koji prikazuje zavisnost funkcionalnosti mreže (relativna veličina LSCC) o procentu uklonjenih neurona.

Napomena o performansama
Za ovu analizu korišten je *Initial Attack* pristup, što znači da se centralnost čvorova računa samo jednom, na početku simulacije. Iako bi *Recalculated Attack* (ponovno računanje centralnosti nakon svakog uklanjanja) pružio još drastičnije rezultate fragmentacije, odabrani metod pruža jasan dokaz o ranjivosti sistema uz visoku računsku efikasnost.

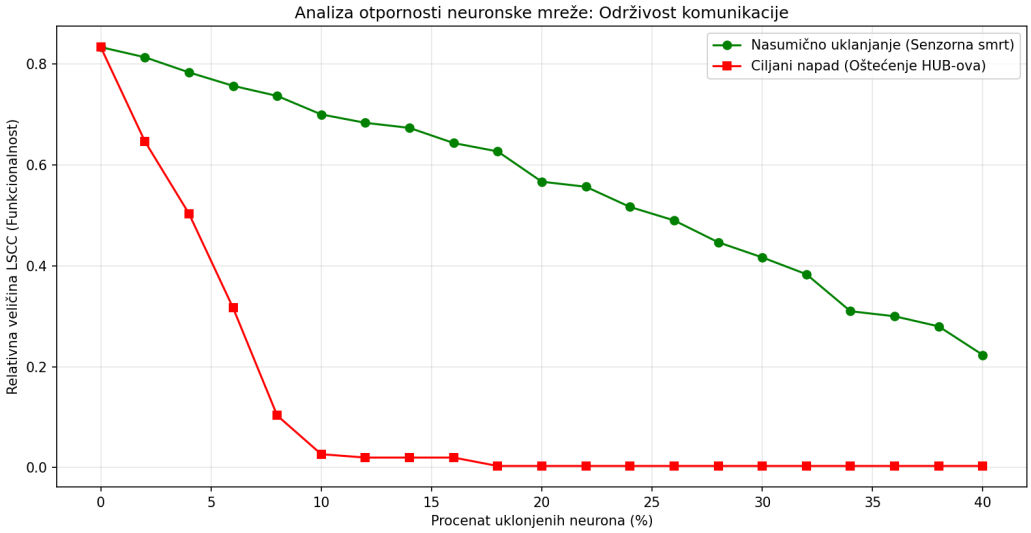

Slika 4: Rezultati analize otpornosti

Vizuelna komparacija trendova

Jasno se uočava divergentno ponašanje dvije strategije. Zelena kriva (**nasumično uklanjanje**) opada linearno: čak i pri gubitku od 20% neurona, mreža zadržava 58% svoje povezanosti, dok pri 40% i dalje održava funkcionalno jezgro od 22%.

Nasuprot tome, crvena kriva (**ciljani napad**) pokazuje nelinearan i katastrofalan pad. Već pri uklanjanju svega 8% hub-čvorova, veličina LSCC-a pada na kritičnih 10%, što predstavlja gotovo osam puta bržu degradaciju u odnosu na nasumični scenario.

Identifikacija kritičnog praga (perkolacija)

U kontekstu teorije grafova, tačka u kojoj LSCC naglo gubi svoju strukturu naziva se perkolacioni prag. Na grafiku se vidi da za ciljani napad taj prag nastupa vrlo rano, već oko 18% uklonjenih čvorova, gdje vrijednost $f_{\text{ciljano}}(\rho)$ dostiže nulu.

Ovo implicira potpunu fragmentaciju mreže u izolovanu "šumu" čvorova. Kod nasumičnog uklanjanja, perkolacioni prag nije dostignut ni pri 40% uklonjenih neurona, što ukazuje na visoku redundantnost i strukturnu rezervu sistema.

Matematička interpretacija ranjivosti

Razlika u nagibu funkcija $f'(\rho)$ direktno potvrđuje da generisana mreža posjeduje *scale-free* topologiju. Kod ovakvih arhitektura važe sljedeća svojstva:

- **Robusnost na greške:** Većina čvorova ima nisku *Betweenness Centrality*. Njihovo uklanjanje ne prekida ključne komunikacione puteve.
- **Ranjivost na napade:** Mali broj hub-čvorova služi kao komunikacioni most između regija. Njihovo uklanjanje eksponencijalno povećava prosječnu dužinu putanje (*Average Path Length*) sve dok globalna komunikacija u potpunosti ne prestane.

5.0.3 Analiza efikasnosti komunikacije (Average Shortest Path Length)

Dok prethodna analiza prati kvantitet preostalih čvorova, ova podsekcija istražuje **kvalitet komunikacije** unutar preostalog dijela mreže mjerenjem prosječne dužine najkraćeg puta (L).

Matematički model efikasnosti
Za usmjereni graf $G = (V, E)$, prosječna dužina najkraćeg puta definisana je kao srednja vrijednost dužina najkraćih putanja između svih mogućih parova čvorova:

$$L = \frac{1}{N(N-1)} \sum_{i \neq j} d(i, j)$$

gdje je:

- N – broj čvorova u posmatranoj komponenti,
- $d(i, j)$ – najkraći put (minimalni broj grana) koji povezuje čvor v_i sa čvorom v_j.

U kontekstu simulacije oštećenja, ovu metriku računamo kao funkciju procenta uklonjenih čvorova ρ unutar najveće snažno povezane komponente:

$$L(\rho) = \text{ASPL}(LSCC_\rho)$$

[4]

Implementacija metrike
Za svaku iteraciju uklanjanja čvorova, algoritam izoluje trenutnu najveću snažno povezanu komponentu ($LSCC_\rho$) i izračunava prosječnu dužinu najkraćeg puta koristeći `networkx` funkciju *average_shortest_path_length*. S obzirom na to da je putanja između nepovezanih čvorova matematički beskonačna, fokus na $LSCC$ omogućava precizno praćenje degradacije efikasnosti unutar jezgra koje još uvijek komunicira.

Vizualizacija

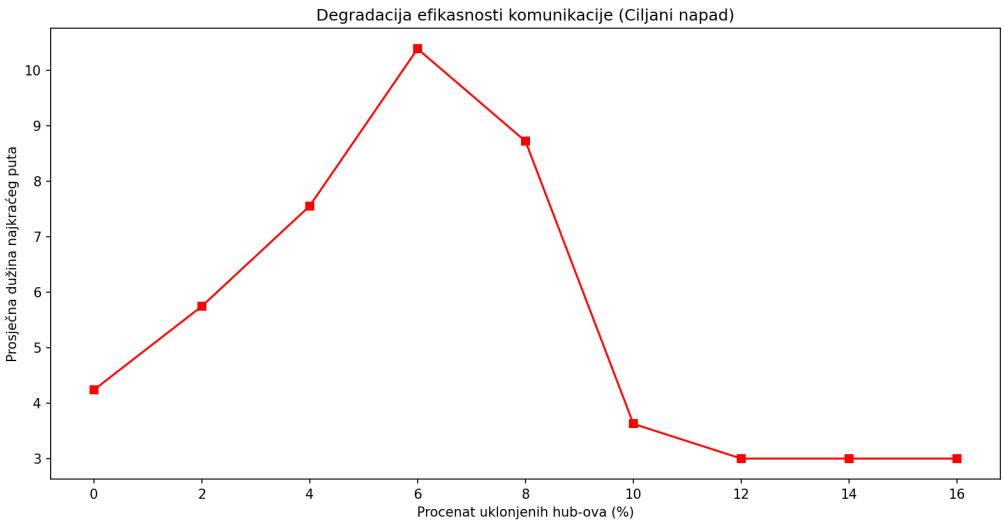

Slika 5: Promjena prosječne dužine najkraćeg puta u zavisnosti od procenta uklonjenih hub-ova. Rast krive ukazuje na gubitak efikasnosti, dok nagli pad signalizira fragmentaciju LSCC-a.

Interpretacija rezultata
Na grafiku uočavamo tri distinktne faze kroz koje mreža prolazi tokom ciljanog napada na hub-neurone:

Faza 1: Eksponencijalni rast i gubitak prečica (0% – 6%)
U početnoj fazi napada, mreža je još uvijek globalno povezana, ali njena efikasnost drastično opada.

- **Trend:** Prosječna dužina puta L raste sa početnih $\approx 4,25$ na maksimalnih $\approx 10,4$.
- **Interpretacija:** Uklanjanjem hub-ova uništavaju se topološke "prečice" koje su omogućavale *small-world* svojstva. Signali su prisiljeni putovati kroz mnogo veći broj perifernih čvorova, što biološki odgovara kognitivnom usporavanju i otežanoj integraciji informacija.

Faza 2: Kritična fragmentacija i kolaps (6% – 10%)
Ovo je najkritičniji period u kojem dolazi do strukturnog pucanja mrežne okosnice.

- **Trend:** Nagli, skoro vertikalni pad vrijednosti L sa $10,4$ na otprilike $3,6$.
- **Fenomen prividnog poboljšanja:** Ovaj pad ne označava povratak efikasnosti, već **fragmentaciju mreže**. Budući da se prosječna putanja računa samo za parove čvorova koji su još uvijek povezani, dugačke putanje nestaju jer se mreža raspala na izolovane otoke (klastere). Globalna komunikacija je u ovoj tački nepovratno prekinuta.

Faza 3: Rezidualni plato i lokalna izolacija (10% – 16%)
U završnoj fazi, mreža prestaje postojati kao jedinstven sistem.

- **Trend:** Vrijednost L se stabilizuje i polako opada prema minimalnoj vrijednosti od $\approx 3,0$.
- **Značenje:** Preostali su samo mali, lokalni klasteri neurona koji su fizički blizu jedni drugima. Prosječna putanja je kratka isključivo zato što su jedini preostali "razgovori" svedeni na neposredne susjede unutar izolovanih fragmenata.

Sinteza rezultata:
Kombinovana analiza LSCC-a i prosječne putanje pokazuje da je za kolaps kognitivne arhitekture dovoljno ukloniti zanemariv broj ključnih čvorišta. Tačka od 6% predstavlja prag nakon kojeg neuronski sistem gubi sposobnost da funkcioniše kao integrisana cjelina. Rezultati potvrđuju osnovnu ideju koja leži u osnovu cijelog rada, a to je da je efikasnost neuronske mreže ekstremno osjetljiva na visokocentralizovane čvorove.

6 Poveznica s vještačkim neuronskim mrežama

Obzirom da su vještačke neuronske mreže danas jedan od najzastupljenijih i najaktivnije istraživanih modela u oblasti obrade informacija, prirodno se nameće pitanje njihove povezanosti sa grafovskim modelima korištenim u ovom radu. Imajući u vidu izražene strukturne i dinamičke sličnosti između bioloških i vještačkih neuronskih mreža, u ovoj sekciji razmatra se na koji način predstavljeni grafovski pristup može biti primijenjen i interpretiran u kontekstu vještačkih neuronskih mreža.
Kako bi se ova veza sagledala na sistematičan način, analizu ćemo započeti razmatranjem strukturnih ekvivalencija između grafovskog modela korištenog u ovom radu i modela vještačkih neuronskih mreža.

6.1 Strukturalna veza između grafovskog modela i vještačkih neuronskih mreža

U formalnom smislu, vještačke neuronske mreže mogu se opisati kao usmjereni težinski grafovi, pri čemu neuroni predstavljaju čvorove grafa, dok sinaptičke veze sa pridruženim težinama odgovaraju usmjerenim granama.[9] Ovakav opis u potpunosti je u skladu sa grafovskim modelom korištenim u ovom radu, gdje je neuronska mreža predstavljena putem matrice susjedstva koja kodira strukturu i jačinu međusobnih veza između čvorova.

U tom kontekstu, matrica težina vještačke neuronske mreže matematički je ekvivalentna matrici susjedstva usmjerenog težinskog grafa. Svaki element matrice određuje doprinos jednog neurona aktivnosti drugog, čime se jasno uspostavlja veza između grafovske reprezentacije mreže i standardnog formalizma korištenog u umjetnim neuronskim mrežama. Ova ekvivalencija omogućava da se strukturne karakteristike analizirane u prethodnim poglavljima direktno interpretiraju i u kontekstu arhitekture vještačkih neuronskih mreža.

Posebno značajnu ulogu u oba sistema imaju čvorovi sa visokim stepenom povezanosti, odnosno visokom centralnošću. U biološkom kontekstu, takvi čvorovi predstavljaju neurone sa ključnom ulogom u integraciji i distribuciji signala, dok se u vještačkim neuronskim mrežama mogu povezati sa neuronima ili slojevima koji imaju dominantan uticaj na tok informacija kroz mrežu. Analiza centralnosti provedena u ovom radu stoga omogućava identifikaciju strukturno kritičnih elemenata mreže, čiji gubitak ili promjena može značajno narušiti funkcionalnost sistema.

Dodatno, prisustvo modularne organizacije u grafovskoj strukturi neuronske mreže može se povezati sa slojevitom ili hijerarhijskom organizacijom vještačkih neuronskih mreža. Iako su ove arhitekture implementacijski različite, osnovni princip grupisanja funkcionalno srodnih čvorova ostaje zajednički, što ukazuje na to da grafovska analiza može pružiti vrijedan uvid u organizaciju i dizajn neuronskih mrežnih arhitektura, nezavisno od njihove biološke ili vještačke prirode.

6.2 Dinamička veza: propagacija signala u vještačkim neuronskim mrežama

Pored strukturne sličnosti, između grafovskog modela razmatranog u ovom radu i vještačkih neuronskih mreža postoji i izražena paralela u pogledu dinamike propagacije signala kroz mrežu. U oba slučaja, aktivnost pojedinačnih čvorova zavisi od ulaznih signala koje primaju od svojih susjeda, kao i od jačine veza koje ih povezuju.

Diskretni model dinamike korišten u ovom radu, u kojem se stanje svakog čvora ažurira u sukcesivnim vremenskim koracima na osnovu ponderisane sume ulaznih signala, konceptualno odgovara mehanizmu forward-pass propagacije u vještačkim neuronskim mrežama[10]. Neto ulazni signal neurona u oba sistema formira se kao linearna kombinacija izlaza prethodnih čvorova, nakon čega se primjenjuje nelinearno pravilo aktivacije koje određuje novo stanje neurona.

Uvedeni prag aktivacije i mehanizam disipacije signala dodatno naglašavaju ovu analogiju. Prag se može posmatrati kao pojednostavljena verzija aktivacione funkcije, dok disipacija ograničava nekontrolisani rast aktivnosti u mreži, slično ulozi regularizacionih mehanizama u vještačkim neuronskim mrežama. Na taj način, grafovski model omogućava intuitivno i matematički utemeljeno razmatranje stabilnosti i ponašanja mreže tokom propagacije signala. Ovaj princip lokalne propagacije informacija kroz graf predstavlja temelj moderne klase modela poznatih kao grafovske neuronske mreže (GNN), koje direktno koriste grafovsku strukturu podataka za učenje.

Iako se u ovom radu ne razmatra optimizacija mreže putem gradijentnih metoda, korištena dinamička pravila jasno ukazuju na opšti princip lokalne obrade informacija, koji predstavlja osnovu i bioloških i vještačkih neuronskih sistema. Time se pokazuje da grafovski pristup nije ograničen isključivo na strukturnu analizu, već pruža i okvir za proučavanje dinamičkih procesa u neuronskim mrežama.

6.3 Otpornost i robusnost neuronskih arhitektura

Analiza otpornosti neuronske mreže predstavlja jedan od ključnih aspekata razmatranih u ovom radu, a njeni rezultati imaju jasne implikacije i za oblast vještačkih neuronskih mreža. Otpornost mreže ispitivana je kroz uklanjanje čvorova, pri čemu su razmatrani kako slučajni, tako i ciljano odabrani poremećaji strukture.

Slučajno uklanjanje čvorova može se povezati sa regularizacionim tehnikama koje se koriste u vještačkim neuronskim mrežama, poput dropout-a, gdje se tokom procesa učenja privremeno deaktiviraju nasumično odabrani neuroni. Rezultati dobijeni u ovom radu ukazuju na to da mreže sa skalno-invarijantnom strukturom zadržavaju visok stepen funkcionalnosti uprkos nasumičnim gubicima čvorova, što je u skladu sa empirijskim zapažanjima o robusnosti dubokih neuronskih mreža.

Nasuprot tome, ciljano uklanjanje čvorova sa visokom centralnošću dovodi do značajnog narušavanja mrežne funkcionalnosti. Ovakav scenario ima direktnu analogiju u vještačkim neuronskim mrežama, gdje gubitak ili degradacija ključnih neurona ili slojeva može imati disproporcionalno veliki uticaj na performanse sistema. Time se dodatno naglašava značaj identifikacije strukturno kritičnih elemenata mreže prilikom njenog dizajna i analize.

Analiza otpornosti provedena u ovom radu pokazuje da grafovska topologija ima presudan uticaj na stabilnost i pouzdanost neuronske mreže. Ovi nalazi ukazuju na to da alati teorije grafova mogu imati važnu ulogu u procjeni robusnosti vještačkih neuronskih arhitektura, posebno u kontekstu njihove primjene u realnim, često neidealnim uslovima.

Zaključne napomene Na osnovu razmatranih strukturnih, dinamičkih i robusnosnih aspekata, može se zaključiti da grafovski modeli predstavljaju zajednički i ujedinjujući matematički okvir za analizu kako bioloških tako i vještačkih neuronskih mreža. Pristup korišten u ovom radu omogućava da se ključne osobine neuronskih sistema sagledaju nezavisno od njihove konkretne implementacije, čime se otvara prostor za primjenu istih metoda i u analizi savremenih vještačkih neuronskih arhitektura. Ova perspektiva dodatno potvrđuje relevantnost grafovske analize u proučavanju složenih neuronskih mreža.

7 Zaključak

Ovaj seminarski rad pružio je sveobuhvatan uvid u primjenu teorije grafova u analizi kompleksnih neuronskih sistema, istražujući neraskidivu povezanost između strukture, dinamike i otpornosti mreže. Polazna premisa rada — da se apstraktni matematički modeli, poput usmjerenih težinskih grafova, mogu koristiti kao rigorozan alat za dešifrovanje principa organizacije mozga — uspješno je demonstrirana kroz tri faze istraživanja.

U prvoj fazi, primjenom Barabási-Albertovog modela, potvrđeno je da biološki neuronski sistemi počivaju na *scale-free* topologiji. Identifikacija ključnih čvorova (*hubs*) putem metrika centralnosti pokazala je da efikasnost mreže ne zavisi od kvantiteta veza, već od njihove strateške distribucije.

Druga faza nadogradila je ovu strukturalnu osnovu dinamičkom komponentom. Upravo u ovom segmentu leži ključni značaj provedene simulacije: ona nije samo vizualizirala statične veze, već je kroz implementaciju Daleovog zakona dokazala da stabilnost sistema ovisi o preciznom balansu ekscitacije i inhibicije. Simulacija je potvrdila da bez inhibitornih mehanizama, čak i topološki savršena mreža gubi funkcionalnost uslijed nekontrolisane propagacije signala.

Konačno, analiza otpornosti u trećoj fazi otkrila je kritičnu ranjivost sistema: dok je mreža izuzetno robusna na nasumična oštećenja, gubitak svega 6% najznačajnijih čvorova vodi ka potpunom funkcionalnom kolapsu.

Poseban doprinos ovog rada predstavlja uspostavljanje formalne analogije između bioloških i vještačkih neuronskih mreža (ANN). Identifikovana sličnost između biološke disipacije i vještačke regularizacije, kao i između nasumičnog uklanjanja čvorova i *dropout* tehnika, ukazuje na to da su principi biološke efikasnosti duboko utkani u temelje moderne vještačke inteligencije.

Ipak, aktuelni model, unatoč svojoj informativnosti, podložan je značajnim poboljšanjima u budućim iteracijama kako bi se vjernije aproksimirala biološka stvarnost:

- **Uvođenje sinaptičke plastičnosti:** Trenutne fiksne težine treba zamijeniti mehanizmima učenja poput STDP (*Spike-Timing-Dependent Plasticity*), omogućavajući mreži da evoluira na osnovu aktivnosti.
- **Složeniji modeli neurona:** Implementacija *Leaky Integrate-and-Fire* (LIF) modela omogućila bi precizniju vremensku dinamiku u odnosu na trenutni sumirajući model.
- **Prostorna ograničenja:** Uvođenje trodimenzionalnog prostora u generiranje grafa omogućilo bi analizu energetske "cijene" dugih veza.

Ova predložena poboljšanja služe kao konceptualna podloga za dalja istraživanja autorice. Razumijevanje načina na koji biološki grafovi balansiraju robusnost i energetsku efikasnost predstavlja direktan putokaz ka optimizaciji vještačkih arhitektura, specifično kroz primjenu grafovskih algoritama i GNN arhitektura u razvoju robusnijih sistema.

U konačnici, rad potvrđuje da kompleksnost neuronskih sistema ne proizlazi iz nasumičnog haosa, već iz strogo definisane topološke arhitekture. Teorija grafova se u ovom kontekstu ne nameće samo kao deskriptivni alat, već kao ključ za razumijevanje same suštine inteligencije. Sumirajući dobijene rezultate, možemo zaključiti da mozak predstavlja vrhunski optimizovanu mrežu čija elegancija leži u matematičkim pravilima koja upravljaju svakim njegovim čvorom i vezom.

8 Reference

[1] Bullmore, E., & Sporns, O. (2009). Complex brain networks: graph theoretical analysis of structural and functional systems. *Nature Reviews Neuroscience*, 10(3), 186–198.

[2] Jurić, Ž. (2024). *Elementi teorije grafova (Predavanje 9).* Radna skripta za kurs Diskretna matematika, Elektrotehnički fakultet u Sarajevu, akademska godina 2024/25.

[3] Barabási, A. L. (2016). *Network Science.* Cambridge University Press.

[4] Newman, M. E. J. (2018). *Networks.* Oxford University Press.

[5] Purves, D., Augustine, G. J., Fitzpatrick, D., Hall, W. C., LaMantia, A.-S., Mooney, R., Platt, M. L., & White, L. E. (2018). *Neuroscience* (6th ed.). Oxford University Press.

[6] Chartrand, G., Lesniak, L., & Zhang, P. (2010). *Graphs & Digraphs* (5. izdanje). CRC Press, Taylor & Francis Group.

[7] Albert, R., Jeong, H., & Barabási, A. L. (2000). Error and attack tolerance of complex networks. *Nature*, 406(6794), 378–382.

[8] Watts, D. J., & Strogatz, S. H. (1998). Collective dynamics of 'small-world' networks. *Nature*, 393(6684), 440–442.

[9] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning.* MIT Press.

[10] Bronstein, M. M., Bruna, J., LeCun, Y., Szlam, A., & Vandergheynst, P. (2017). Geometric deep learning: going beyond euclidean data. *IEEE Signal Processing Magazine*, 34(4), 18–42.

A Programski kod

U ovom dijelu rada priložen je cjelokupan izvorni kod implementiran u programskom jeziku *Python*.

```python
import networkx as nx
import numpy as np
import matplotlib.pyplot as plt
from matplotlib.animation import FuncAnimation
from matplotlib.lines import Line2D
from matplotlib.collections import LineCollection
import copy
from matplotlib.patches import FancyArrowPatch
import time
from networkx.algorithms import community

#Faza 1: Generisanje mreže
def generisi_mrezu(N=300, m=3):

    G_undirected = nx.barabasi_albert_graph(n=N, m=m, seed=42)

    G = nx.DiGraph()
    G.add_nodes_from(G_undirected.nodes())

    for n in G.nodes():
        G.nodes[n]['type'] = 'E' if np.random.rand() < 0.8 else 'I'

    for u, v in G_undirected.edges():
        if np.random.rand() < 0.5:
            src, dst = u, v
        else:
            src, dst = v, u


        tip_izvora = G.nodes[src]['type']
        if tip_izvora == 'E':

            tezina = np.random.uniform(0.1, 1.0)
        else:

            tezina = np.random.uniform(-1.0, -0.1)

        G.add_edge(src, dst, weight=tezina)

    return G

N = 300
G = generisi_mrezu(N)
print(f"Generisana mreza sa {G.number_of_nodes()} cvorova i {G.number_of_edges()} veza.")

degrees_dict = dict(G.degree())
degrees_list = [d for n, d in G.degree()]

sorted_degrees = sorted(G.degree, key=lambda x: x[1], reverse=True)
top_hub_node = sorted_degrees[0][0]
periferni_node = sorted_degrees[-1][0]

print(f"Najveci HUB je cvor {top_hub_node} sa stepenom {sorted_degrees[0][1]}.")
print(f"Najmanji periferni cvor je {periferni_node} sa stepenom {sorted_degrees[-1][1]}.")

#centralnost
bc = nx.betweenness_centrality(G)
top_bc = sorted(bc.items(), key=lambda x: x[1], reverse=True)[0]
print(f"Cvor sa najvecom Betweenness centralnoscu je {top_bc[0]} (vrijednost: {top_bc[1]:.4f})")
#klasterisanje
avg_clustering = nx.average_clustering(G.to_undirected())
print(f"Prosjecni koeficijent klasterisanja: {avg_clustering:.4f}")
#modularnost
communities = community.greedy_modularity_communities(G.to_undirected())
```

```python
print(f"Broj detektovanih funkcionalnih modula (zajednica): {len(communities)}")

plt.figure(figsize=(10, 5))
plt.hist(degrees_list, bins=30, color='skyblue', edgecolor='black')
plt.title("Distribucija stepena čvorova (Barabási-Albert model)")
plt.xlabel("Stepen čvora (k)")
plt.ylabel("Broj čvorova")
plt.yscale('log')
plt.grid(True, alpha=0.3)
plt.show()

# Kategorizacija za statički prikaz
num_hubs = int(N * 0.05)
num_mid = int(N * 0.15)
hubs = [n for n, d in sorted_degrees[:num_hubs]]
mid_nodes = [n for n, d in sorted_degrees[num_hubs:num_hubs+num_mid]]

node_colors_static = []
for n in G.nodes():
    if n in hubs: node_colors_static.append('#FF3333')
    elif n in mid_nodes: node_colors_static.append('#FFCC33')
    else: node_colors_static.append('#3399FF')

plt.figure(figsize=(12, 10))
pos = nx.spring_layout(G, k=0.3, seed=42)

node_sizes = [degrees_dict[n]*15 for n in G.nodes()]


nx.draw_networkx_edges(
    G, pos,
    alpha=0.1,
    edge_color='gray',
    arrows=True,
    arrowsize=10,
    node_size=node_sizes,
    connectionstyle="arc3,rad=0.05"
)


nx.draw_networkx_nodes(
    G, pos,
    node_size=node_sizes,
    node_color=node_colors_static,
    alpha=0.8
)

legend_elements = [
    Line2D([0], [0], marker='o', color='w', label='Hub neuroni (Gornjih 5%)',
           markerfacecolor='#FF3333', markersize=12),
    Line2D([0], [0], marker='o', color='w', label='Srednji neuroni (5-20%)',
           markerfacecolor='#FFCC33', markersize=9),
    Line2D([0], [0], marker='o', color='w', label='Periferni neuroni (80%)',
           markerfacecolor='#3399FF', markersize=6)
]

plt.legend(
    handles=legend_elements,
    title="Kategorije čvorova",
    fontsize=10,
    loc='upper right',
    bbox_to_anchor=(1.04, 1.06)
)

plt.title("Topološka struktura mreže")
plt.axis('off')
plt.show()
```

```python
# Faza 2: Simulacija dinamike širenja
def simuliraj_dinamiku(G, pocetni_cvor, koraci=50, pocetni_theta=0.35, disipacija=0.15, eta=0.08):
    tezin_kopija = {(u, v): G[u][v]['weight'] for u, v in G.edges()}
    energija = {n: 1.0 for n in G.nodes()}
    stanja = {n: 0 for n in G.nodes()}

    stanja[pocetni_cvor] = 1
    istorija = []

    for t in range(koraci):
        nova_stanja = {n: 0 for n in G.nodes()}

        aktivne_veze_u_koraku = []

        for i in G.nodes():
            if stanja[i] != 0: continue

            suma_ulaza = sum(tezin_kopija[(j, i)] * stanja[j] for j in G.predecessors(i))
            neto = suma_ulaza - disipacija

            if energija[i] > 0.85 and abs(neto) > pocetni_theta:
                nova_stanja[i] = 1 if neto > 0 else -1
                energija[i] = 0.0

                for j in G.predecessors(i):
                    if stanja[j] != 0:
                        tezin_kopija[(j, i)] += eta
                        tezin_kopija[(j, i)] = np.clip(tezin_kopija[(j, i)], -2.0, 2.0)

                        aktivne_veze_u_koraku.append((j, i))

        istorija.append({'stanja': stanja.copy(), 'putanje': aktivne_veze_u_koraku})
        stanja = nova_stanja.copy()

        if sum(abs(s) for s in stanja.values()) == 0 and t > 5: break

    return istorija

def pokreni_animaciju(G, istorija, naslov="Dinamika"):
    plt.close('all')
    fig, ax = plt.subplots(figsize=(11, 8), facecolor='black')
    ax.set_facecolor('black')
    particles = ax.scatter([], [], s=10, color='white', alpha=0.9, zorder=7)

    velicina_cvorova = 25

    print("Pripremam pozadinu...")
    nx.draw_networkx_edges(
        G, pos_anim,
        alpha=0.03,
        edge_color='gray',
        width=0.5,
        arrows=True,
        arrowsize=7,
        ax=ax,
        node_size=velicina_cvorova,
        connectionstyle="arc3,rad=0.1"
    )

    cvorovi_objekt = nx.draw_networkx_nodes(
        G, pos_anim,
        node_size=velicina_cvorova,
        node_color=['#111111']*len(G.nodes()),
        ax=ax,
        edgecolors='#222222',
        linewidths=0.3
    )
    time.sleep(3)
```

```python
    interp_steps = 20
    interval_ms = 30

    def update(frame):
        step_idx = frame // interp_steps
        intra_step = frame % interp_steps

        if step_idx >= len(istorija):
            particles.set_offsets(np.empty((0, 2)))
            return cvorovi_objekt, particles

        podaci = istorija[step_idx]

        if intra_step == 0:
            nove_boje = ['#111111'] * len(G.nodes())
            for n, s in podaci['stanja'].items():
                if s == 1: nove_boje[n] = '#FF3333'
                elif s == -1: nove_boje[n] = '#3333FF'
            cvorovi_objekt.set_facecolors(nove_boje)

        aktivni_parovi = podaci['putanje']
        coords = []
        if aktivni_parovi:
            for u, v in aktivni_parovi:
                start = np.array(pos_anim[u])
                end = np.array(pos_anim[v])

                progress = intra_step / interp_steps
                if 0 <= progress <= 1:
                    point = (1 - progress) * start + progress * end
                    coords.append(point)

        if coords:
            particles.set_offsets(coords)
            particles.set_alpha(0.9)
        else:
            particles.set_offsets(np.empty((0, 2)))

        return cvorovi_objekt, particles

    ani = FuncAnimation(
        fig, update,
        frames=len(istorija) * interp_steps,
        interval=interval_ms,
        blit=True,
        repeat=False
    )

    plt.title(naslov, color='white', pad=20)
    plt.axis('off')
    plt.show()

pos_anim = nx.spring_layout(G, k=0.4, seed=42)

def sacuvaj_snapshots(G, istorija, pos, prefix="hub_snapshot", koraci_snapshot=[0,5,10,15]):
    degrees_dict = dict(G.degree())
    velicine_dict = {n: 40 + degrees_dict[n]*8 for n in G.nodes()}

    for t in koraci_snapshot:
        if t >= len(istorija):
            continue

        podaci = istorija[t]

        boje = []
        for n in G.nodes():
            s = podaci['stanja'][n]
            if s == 1:
```

```
                boje.append('#FF3333')
            elif s == -1:
                boje.append('#3333FF')
            else:
                boje.append('#AAAAAA')

        plt.figure(figsize=(12,10))
        ax = plt.gca()

        nx.draw_networkx_edges(G, pos, alpha=0.03, edge_color='gray', arrows=False)

        nx.draw_networkx_nodes(G, pos, node_color=boje, node_size=list(velicine_dict.values()),
                               alpha=0.9, edgecolors='#555555', linewidths=0.5)

        aktivne_veze = podaci['putanje']
        if aktivne_veze:
            for u, v in aktivne_veze:
                radius_u = np.sqrt(velicine_dict[u]/np.pi) * 0.015
                radius_v = np.sqrt(velicine_dict[v]/np.pi) * 0.015

                arrow = FancyArrowPatch(
                    posA=pos[u], posB=pos[v],
                    arrowstyle='-|>',
                    color='red',
                    mutation_scale=15,
                    lw=1.8,
                    alpha=0.9,
                    connectionstyle="arc3,rad=0.1",
                    shrinkA=radius_u,
                    shrinkB=radius_v
                )
                ax.add_patch(arrow)
        plt.xlim(-1.1, 1.1)
        plt.ylim(-1.1, 1.1)
        plt.axis('off')
        plt.title(f"Vizualizacija širenja: Korak {t}", fontsize=14)
        plt.savefig(f"{prefix}_{t:02d}.png", dpi=150, bbox_inches='tight', pad_inches=0.1)
        plt.close()
        print(f"Generisana slika: {prefix}_{t:02d}.png")

# --- analiza otpornosti ili Faza 3 ---
def analiza_otpornosti(G_original, procenat_uklanjanja=0.4, korak=0.02):
    print("\nPokrećem analizu otpornosti (LSCC)...")
    N = G_original.number_of_nodes()
    koraci = np.arange(0, procenat_uklanjanja + korak, korak)

    lscc_nasumicno = []
    lscc_ciljano = []
    svi_cvorovi = list(G_original.nodes())
    np.random.shuffle(svi_cvorovi)
    for p in koraci:
        temp_G = copy.deepcopy(G_original)
        temp_G.remove_nodes_from(svi_cvorovi[:int(p * N)])
        komp = sorted(nx.strongly_connected_components(temp_G), key=len, reverse=True)
        lscc_nasumicno.append(len(komp[0]) / N if komp else 0)

    bc_scores = nx.betweenness_centrality(G_original)
    poredani_cvorovi = [n for n, v in sorted(bc_scores.items(), key=lambda x: x[1], reverse=True)]
    for p in koraci:
        temp_G = copy.deepcopy(G_original)
        temp_G.remove_nodes_from(poredani_cvorovi[:int(p * N)])
        komp = sorted(nx.strongly_connected_components(temp_G), key=len, reverse=True)
        lscc_ciljano.append(len(komp[0]) / N if komp else 0)

    plt.figure(figsize=(10, 6))
    plt.plot(koraci * 100, lscc_nasumicno, 'o-', label='Nasumično uklanjanje (Senzorna smrt)',
    ↪  color='green')
```

```python
    plt.plot(koraci * 100, lscc_ciljano, 's-', label='Ciljani napad (Oštećenje HUB-ova)', color='red')
    plt.title("Analiza otpornosti neuronske mreže: Održivost komunikacije")
    plt.xlabel("Procenat uklonjenih neurona (%)")
    plt.ylabel("Relativna veličina LSCC (Funkcionalnost)")
    plt.grid(True, alpha=0.3)
    plt.legend()
    plt.show()

print("\nPokrećem Simulaciju A (HUB)... Gledajte veze koje zasvijetle.")
start_time = time.time()
istorija_hub = simuliraj_dinamiku(G, pocetni_cvor=top_hub_node)
end_time = time.time()
print(f"Scenario A (HUB) trajao je {end_time - start_time:.3f} sekundi.")
pos_anim = nx.spring_layout(G, k=0.4, seed=42)

n_snap = 4
koraci_snapshot = np.linspace(0, len(istorija_hub)-1, n_snap, dtype=int)
sacuvaj_snapshots(G, istorija_hub, pos_anim, prefix="hub_snapshot", koraci_snapshot=koraci_snapshot)

pokreni_animaciju(G, istorija_hub, naslov="Scenario A: Aktivacija iz HUB-a")

start_time = time.time()
istorija_periferija = simuliraj_dinamiku(G, pocetni_cvor=periferni_node)
end_time = time.time()
print(f"Scenario B (Periferija) trajao je {end_time - start_time:.3f} sekundi.")
pos_anim = nx.spring_layout(G, k=0.4, seed=42)


n_snap = 4
koraci_snapshot = np.linspace(0, len(istorija_periferija)-1, n_snap, dtype=int)

istorija_periferija = simuliraj_dinamiku(G, pocetni_cvor=periferni_node)

sacuvaj_snapshots(G, istorija_periferija, pos_anim, prefix="periferija_snapshot", koraci_snapshot=koraci_snapshot)

pokreni_animaciju(
    G,
    istorija_periferija,
    naslov="Scenario B: Aktivacija iz periferije"
)

analiza_otpornosti(G)

#analiza putanja
def analiza_putanja(G_original, procenat_uklanjanja=0.2, korak=0.02):
    N = G_original.number_of_nodes()
    koraci = np.arange(0, procenat_uklanjanja + korak, korak)

    avg_put_ciljano = []

    bc_scores = nx.betweenness_centrality(G_original)
    poredani_cvorovi = [n for n, v in sorted(bc_scores.items(), key=lambda x: x[1], reverse=True)]

    for p in koraci:
        temp_G = copy.deepcopy(G_original)
        temp_G.remove_nodes_from(poredani_cvorovi[:int(p * N)])

        komp = sorted(nx.strongly_connected_components(temp_G), key=len, reverse=True)
        if komp and len(komp[0]) > 1:
            lscc_subgraph = temp_G.subgraph(komp[0])
            avg_l = nx.average_shortest_path_length(lscc_subgraph)
            avg_put_ciljano.append(avg_l)
        else:
            avg_put_ciljano.append(None)

```

```
    return koraci * 100, avg_put_ciljano

procenti, putanje = analiza_putanja(G)
plt.plot(procenti, putanje, 's-', color='red')
plt.title("Degradacija efikasnosti komunikacije (Ciljani napad)")
plt.xlabel("Procenat uklonjenih hub-ova (%)")
plt.ylabel("Prosječna dužina najkraćeg puta")
plt.show()
```